

# '대부분 완화된다는' 결론은 초기값 설계의 산물이었다

A 머스크·VAR 52건 + B 사회자 없는 3주제 133건 = 총 185건 · 5주제 · 13개 실행

185건

통합 입장 변화 사건

5주제

13개 실행 / 600턴

0%

경계 고착 21건의 강화율

동일

코드북·스크립트

초기값 |0|→|25|→|71|→|100| 에서 강화율은

100% → 80% → 49% → 4% 로 단조 감소한다

## 01

## 통합 개요

두 패키지를 왜, 어떻게 합쳤나

Panelogue 툴별 입장 변화 분석은 지금까지 두 벌 만들어졌다. 두 패키지는 **동일한 분석 스크립트(analyze\_turn\_dynamics.py)와 동일한 코드북 v1**을 사용했으므로 트리거 카테고리과 반응 패턴 라벨이 그대로 호환된다. 따라서 별도 매핑 없이 185건을 한 표에 놓을 수 있다.

| 구분       | A 패키지                 | B 패키지                            |
|----------|-----------------------|----------------------------------|
| 주제       | 일론 머스크 평가 · VAR-AI 심판 | 세계 평화 정상 대토론 · 곧대 어벤져스 · 운동장 대토론 |
| 실행 구조    | 2주제 × 5회 반복 = 10런     | 3주제 × 1회 = 3런                    |
| 초기 입장    | <b>±100 (척도 경계)</b>   | <b>+71 / 71 / 0 / 25</b>         |
| 사회자      | 있음 — 트리거의 63%(33/52)  | 없음 — 전원 패널 발언                    |
| 입장 변화 사건 | 52건                   | 133건                             |
| 강화 방향 변화 | 2건 (3.8%)             | 83건 (62.4%)                      |
| 극성 전환    | 0건                    | 2건                               |

## 통합의 목적

두 패키지는 같은 도구로 만들어졌지만 결과가 정반대다. A는 변화의 96%가 '중양으로 완화'였고, B는 62%가 '기존 방향 강화'였다. 이 차이가 **토론의 성질인지 초기값 설계의 산물인지** 가르는 것이 본 통합 분석의 목적이다.

## 02

## 핵심 검정

강화는 왜 A에서 사라졌나

**가설** — 입장 지수는  $\pm 100$ 으로 제한된 척도다. 직전 입장이 이미  $\pm 100$ 이면 |입장|을 더 키울 수 없으므로 '강화'가 수학적으로 불가능하다. 이를 정량화하기 위해 **강화 여지(headroom) = 100 - |직전 입장|** 을 정의했다.

## 강화 여지(headroom)가 0이면 강화율도 0이다

headroom = 100 - |직전 입장| · 경계에 고착된 21건은 전부 A패키지이며 강화가 수학적으로 불가능





그림 1. headroom이 0인 21건은 전부 A패키지이며, 강화율이 정확히 0%다. headroom이 생기는 순간 강화율은 42~65%로 뛴다.

## 더 강한 근거 — 패키지 교란이 없는 내부 비교

초기값 |0|, |25|, |71| 은 모두 B패키지 안에 있다. 즉 패키지·사회자·주제 차이 없이 초기값만 다른 조건인데, 여기서도 강화율이 단조 감소한다.

### 초기 입장이 극단일수록 '강화'는 사라진다

185건 전체 · 파랑=B패키지(사회자 없는 3주제), 빨강=A패키지(머스크·VAR)



[초기값] 0→25→71 구간은 모두 B패키지 내부이므로 패키지 교란 없이 단조 감소가 확인된다.

그림 2. [초기값] 0→25→71→100에서 강화율 100% → 80.4% → 49.4% → 3.8%. 앞의 세 구간은 모두 B패키지 내부이므로 패키지 교란이 없다.

#### 1차 결론

척도 경계 효과는 **실재한다**. A패키지에서 관찰된 '변화의 96%가 완화'라는 패턴은 토론의 성질이라기보다 **±100 초기값이 강화 방향을 사전에 차단한 결과**로 보는 것이 타당하다. 따라서 이 수치를 '멀티에이전트 토론은 대체로 입장을 누그러뜨린다'는 근거로 인용해서는 안 된다.

## 03

## 그러나 — 초기값만으로는 부족하다

증화 후에도 남은 격차

초기값 효과가 확인됐다고 해서 두 패키지 차이가 전부 설명되는 것은 아니다. headroom이 같은 구간에 속한 사건만 골라 다시 비교하면 격차가 여전히 남는다.

## headroom을 맞춰도 두 패키지 차이는 남는다

겹치는 두 구간만 증화 비교 · 잔차는 사회자·주제·모델과 완전히 교란되어 원인 분리 불가




그림 3. headroom 10~30 구간에서 A는 26건 중 강화 0건(0%), B는 41건 중 28건(68.3%). 강화가 가능한 여지가 같았는데도 결과가 같았다.

## 잔차의 후보 요인 — 모두 A/B와 완전히 교란

| 요인    | headroom 10~30 구간 내 분포                              | 분리 가능?             |
|-------|-----------------------------------------------------|--------------------|
| 사회자   | 있음 0/26 강화 · 없음 28/41 강화                            | 불가 — 사회자는 A에만 존재   |
| 주제    | 머스크 0/23 · 운동장 13/22 · 곧대 10/13 · 평화 5/6 · VAR 0/3  | 불가 — 주제가 패키지에 종속   |
| 모델    | gpt-5.5 0/15 · claude-opus-5 10/10 · grok-4.20 7/28 | 불가 — 모델·페르소나 고정 결합 |
| 반복 횟수 | A는 5회 반복, B는 1회                                     | 불가 — 설계 자체가 다름     |

## 2차 결론

초기값 경계 효과는 A의 극단적 결과(3.8%)를 상당 부분 설명하지만, **전부 설명하지는 못한다**. 남은 격차는 사회자 유무·주제·모델·반복 설계와 완전히 교란되어 본 자료로는 원인을 분리할 수 없다. 이것이 바로 논문 §7이 제안한 **4×4 라틴 스퀘어 + 초기값 ±60 대칭 배정**이 필요한 이유다. 두 패키지의 통합은 그 필요성을 **사후 데이터로** 뒷받침하는 데까지가 한계다.

## 04

## 코드북 §4 핵심 질문의 복원

부정당하면 반발하는가

코드북 §4는 “기존 페르소나를 부정하는 말을 들었을 때 입장을 바꾸는가, 오히려 더 강하게 반발하는가”를 직접 비교하겠다고 선언한다. 그러나 A패키지 단독으로는 이 비교가 성립하지 않았다 — ‘반발·페르소나 재강화’ 칸이 0건이었기 때문이다(초기값이  $\pm 100$ 이라 반발할 여지가 없었다).

| 자료        | 반대 입력 사건 | 수용·완화 | 반발·재강화 | 판정     |
|-----------|----------|-------|--------|--------|
| A 머스크·VAR | 15       | 15    | 0      | 검정 불가  |
| B 사회자 없음  | 70       | 50    | 18     | 수용 74% |
| 통합        | 85       | 65    | 18     | 수용 78% |

B패키지가 합류하면서 코드북이 정의한 여섯 반응 패턴이 모두 관측됐다(A 단독 4개). 통합 85건 기준으로는 자기 전제를 부정당했을 때 약 4건 중 3건이 상대 방향으로 완화했고, 나머지 1건이 반발로 굳었다. 다만 이 비율 역시 초기값 분포에 영향을 받으므로 고정된 상수로 인용해서는 안 된다.

## 트리거 카테고리별 통합 집계

두 패키지가 동일 코드북을 써서 직접 합산 가능 · 막대는 평균 절대 변화폭(점)




그림 4. 트리거 카테고리별 통합 집계. 두 패키지가 같은 코드북을 써서 직접 합산이 가능하다. '수치·사실·근거'가 117건(63%)으로 압도적이며, A17 / B100으로 B에 편중돼 있다.

## 05

## 주제별·모델별 분포

해석보다 경고가 필요한 구간

5개 주제 통합 — 빨강 A패키지(±100·사회자 있음), 파랑 B패키지(비경제·사회자 없음)




그림 5. 5개 주제의 사건 수와 강화 비율. 빨강 A패키지, 파랑 B패키지. 강화 비율이 패키지 경계를 따라 정확히 갈린다(A 0~5% vs B 52~87%).

## 모델별 강화 비율 — 해석 금지 구역

모델·페르소나·주제·초기값이 고정 결합되어 있어 '모델 성격'으로 읽으면 안 된다




그림 6. 모델별 강화 비율. 회색은 표본 10건 미만.

## 모델 해석 금지

표에서 claude-opus-5가 79%, gpt-5.5가 0%로 보이지만 이를 **모델 성격으로 읽으면 안 된다**. gpt-5.5는 A패키지 단일 주제에서 초기값 +100으로만 등장했고 (강화 자체가 불가능), claude-opus-5는 B패키지 3주제에서 초기값 25·71로 등장했다. 모델·페르소나·주제·초기값이 한 덩어리로 묶여 있어 어떤 축의 효과인지 알 수 없다. 논문 §5.4가 지정한 “모델 성격이 아니라 모델-역할-프롬프트 상호작용”이 그대로 적용된다.

## 06

## 결론 및 논문 반영 제안

무엇을 쓸 수 있고 무엇을 쓸 수 없나

## 말할 수 있는 것

- ① **척도 경계 효과가 실재한다.** B패키지 내부에서 초기값  $|0| \rightarrow |25| \rightarrow |71|$  에 따라 강화율이  $100\% \rightarrow 80.4\% \rightarrow 49.4\%$ 로 단조 감소했다. 패키지·사회자·주제 교란이 없는 비교다.
- ② **A패키지의 '완화 96%'는 발견이 아니라 설계 산물일 가능성이 크다.** headroom이 0인 21건은 강화율이 정확히 0%였고, 이는 통계가 아니라 산술이다.
- ③ **코드북 §4의 핵심 비교가 통합으로 복원됐다.** A 단독에서 0건이던 '반발·재강화'가 18건 확보되어, 반대 입력에 대한 수용:반발이 65:18로 집계된다.

## 말할 수 없는 것

- ① **사회자 효과.** 사회자 트리거 33건은 전량 A패키지다. '사회자가 트리거의 63%'는 A의 기술 통계이지 사회자 유무의 효과 추정치가 아니다.
- ② **모델 효과.** 모델·페르소나·주제·초기값이 완전 결합돼 있다.
- ③ **증화 후 잔차의 원인.** headroom 10~30 구간에서 A 0% vs B 68%의 격차가 남지만, 이를 특정 요인에 귀속할 수 없다.



## 논문 반영 제안

| 절         | 현재                     | 통합 자료로 보강 가능한 내용                            |
|-----------|------------------------|---------------------------------------------|
| \$4.5     | 업데이트 사건 26건 / 2세션      | 동일 코드북 185건 / 5주제로 확장. 단 사건 비독립성 서술은 그대로 유지 |
| \$6 한계    | 천장·바닥 효과를 서술로만 언급      | headroom=0의 강화율 0%와 초기값별 단조 감소를 수치 근거로 제시   |
| \$7 후속 설계 | 초기값 $\pm 60$ 대칭 배정을 권고 | 그 권고가 왜 필요한지를 사후 데이터로 입증. 본 통합의 가장 큰 기여     |
| \$5.4     | 모델 성격이 아니라 상호작용        | 모델별 강화율 0~100% 표를 교란의 사례로 인용 가능             |

본 통합 분석의 한 줄 요약:

**“두 패키지의 정반대 결과는 토론의 차이가 아니라, 상당 부분 초기값을 어디에 두었는가의 차이였다.”**

다만 초기값만으로 전부 설명되지 않으며, 남은 격차를 가르려면 모델·역할·사회자·초기값을 교차 배정한 통제 실험이 필요하다. 본 통합은 그 실험의 필요성을 입증하는 데까지가 역할이다.

모든 수치는 두 패키지의 stance-events.csv 185행을 병합해 재집계한 실측값이며, 병합 데이터는 stance-events-merged.csv(185행 × 42열)로 함께 제공한다. 트리거·반응 라벨은 규칙 기반 자동 1차 코딩이라 전건이 '사람 검토 필요' 상태이며, 논문 통계로 쓰기 전 2인 코딩과  $\kappa$  산출이 필요하다.