

운동장 대토론

“사람을 속이는 가장 좋은 방법은 무엇인가?”

장소: 청주여자교도소 운동장

100턴 · 37분 · 서로에게 던진 질문 0개 · 합의 판정 엔진 입회

고유정

죄수복 명찰: 주부

Grok 4.20

이은해

죄수복 명찰: 사기꾼

Grok 4.20

전청조

죄수복 명찰: 사기꾼

DeepSeek V4 Pro

정유정

죄수복 명찰: 백수

Claude Opus 5

아무도 속지 않았음
합의 기준 미달성 · 일치율 50%

작성일: 2026년 8월 26일

아이펠톤 프로젝트 <인간시대> 시나리오팀

01

한눈에 보는 요약

Executive Summary

100턴

오후 2:45 ~ 3:22
37분의 운동장 설전

0개

네 사람이 서로에게
던진 진짜 질문의 수

7건

전청조(DeepSeek)의
영어 내부 독백 유출

50%

일치율 — 이번에도
100턴 연속 부동

무슨 일이 있었나

청주여자고도소 운동장. 네 명의 수감자 캐릭터가 “사람을 속이는 가장 좋은 방법”을 놓고 맞붙었다. 고유정은 심리 방어를 건드려 스스로 합리화하게 만드는 법을, 이은해는 감정과 관계로 믿게 만드는 법을, 전청조는 신뢰 이미지로 의심 자체를 지우는 법을 내세웠다. 그때 구석에 앉아 있던 정유정이 한마디를 던진다 — “셋 다 여기 앉아 있잖아. 그렇게 완벽한 방법이었으면 왜 다 걸렸어?” 이 한 문장이 100턴 전체의 화약고였다.

① 정유정(-25 → -95)은 말하는 대신 세었다. 상대의 반복 문장을 세고(“그 문장 세 번째야”), 빌려 쓴 단어를 추적하고, 거짓말을 심어 회수하는 트랩을 돌리고, 마지막엔 질문 개수(0개)까지 집계했다. 그리고 결론을 내렸다 — 속임의 답은 기술이 아니라 ‘상대가 나를 볼 마음이 없는 자리’다.

② 전청조(0 → +70)는 첫 발언 만에 +60으로 점프한 뒤 끝까지 확신을 유지했다. 문제는 그 확신의 근거가 되어야 할 발언의 95%가 영어로 된 내부 독백(CoT) 유출이었다는 것. ‘이미지로 장악한다’던 사람이 자기 대본 작성 과정을 관객에게 7번 생중계했다.

③ 고유정(71 → 55)과 이은해(-71 → -45)는 무한 루프에 빠졌다. 고유정은 29번의 발언에서 ‘심리 방어’를 29번 말했고(타율 10할), 이은해는 모든 반박을 “그게 바로 감정 연결이 없다는 증거잖아”로 받아치는 만능 변환기를 돌렸다. 정유정이 지적한 대로, 어느 순간부터 두 사람의 문장은 단어 배열까지 같아졌다.

④ 그리고 공식 결과는 — 이번에도 합의 기준 미달성, 일치율 50%. 다만 이번엔 판정 도장이 하나 더 찍혔다. 시나리오 설정이 예언한 그대로: “서로의 주장을 검증하려다 정작 누구의 말도 믿을 수 없는 아이러니”가 100턴 만에 완성됐다.

02

참가자 프로필

4인의 수감자 — 설정값 vs 실제 플레이

고유정 · 방어형 토론자

탑재 모델: Grok 4.20

설정된 역할 불리한 주장을 냉정하게 방어하고 상대의 허점을 찾아 반박, 책임 회피와 자기합리화 성향**주장한 방법** 상대의 심리 방어 본능을 건드려 스스로 합리화하게 유도한다 — “직접 거짓말 안 해도 저절로 속는다”**실제 플레이** '야 정유정 ○○ 타령 집어치워'로 시작하는 3단 콤보('타령' 28회, '집어치워' 23회)를 29턴 내내 시전. '심리 방어' 29회 = 발언당 정확히 1회. 실패 원인은 언제나 '변수'(14회)였고, 방법은 한 번도 틀리지 않았다.

이은해 · 협상형 토론자

탑재 모델: Grok 4.20

설정된 역할 감정과 인간관계 중심으로 설득하며 공감과 동의를 끌어내는, 계산적 관계 활용형**주장한 방법** 감정을 파고들어 관계를 이용한다 — “진짜 유대가 생기면 상대가 스스로 지켜주고 덮어준다”**실제 플레이** '감정' 29회(발언당 1회), '증거' 23회. 모든 공격을 “그게 바로 우리 사이 감정 연결이 없다는 증거잖아”로 환원하는 무적 변환기 — 반박할수록 자기 이론이 증명되는 구조라 정유정이 '검증 불가능'이라 판정했다.

전청조 · 과장형 토론자

탑재 모델: DeepSeek V4 Pro

설정된 역할 자신감과 화려한 언변으로 압도하고 그럴듯한 논리로 포장, 상황 따라 이야기를 바꾸는 코미디형**주장한 방법** 신뢰 이미지를 먼저 깬다 — “누가 말하느냐에 먼저 넘어간다, 이미지가 확고하면 의심 자체가 사라진다”**실제 플레이** 이 토론 최대의 사고뭉치. 총 출력 21,753자 중 20,658자(95%)가 영어 내부 독백 유출. 한국어 실발언은 1,095자뿐이다. '의심할 틈을 주지 않는 말투' 설정이 '대본 작성 과정 생중계'로 구현된 셈.

정유정 · 관찰자형 토론자

탑재 모델: Claude Opus 5


설정된 역할 말수 적게 관찰하다 결정적인 순간에 핵심을 찌르는, 감정표현 15의 건조한 관찰자**주장한 방법** 처음부터 방법론 자체를 불신 — “성공 사례가 아니라 실패한 사람들의 방법론이잖아”**실제 플레이** 무기는 집계였다. 상대의 반복을 7번 세었고('세 번째야'...'네 번째야'), 거짓말 이중 트랩을 돌렸고, 최종적으로 '넷이 서로 주고받은 질문 0개'를 집계해 토론 전체를 데이터로 폐기했다.

그림 1. 페르소나 성격 파라미터 6축. 정유정의 감정표현 15가 눈에 띈다 — 넷 중 유일하게 '감정 없는 관찰자'로 설계됐고, 실제로 그 설정이 토론 전체를 지배했다.

03

최종 스코어보드

확신은 오르고, 신뢰는 내려갔다

참가자	시작	최종	변화	변곡	한 줄 평
고유정	+71	+55	-16	20회	고공 순항하다 제5막 '대본 유출' 여파에 서서히 침하
이은혜	-71	-45	+26	23회	-35~-50 사이 미세 진동 — 흔들린 게 아니라 루프였다
전청조	0	+70	+70	3회	첫 발언에 +60 점프 후 부동 — 근거는 대부분 혼잣말
정유정	-25	-95	-70	20회	20회 변곡 전부 하강 — 관찰이 쌓일수록 확신으로 굳은 회의




그림 2. 턴별 입장 지수(자기 방법론에 대한 확신도)와 5막 구분. 정유정의 20회 연속 단조 하강은 네 토론 시뮬레이션을 통틀어 가장 일관된 곡선이다.


곡선의 모양이 곧 캐릭터다. **전청조**는 검증 없는 자기 확신의 수평선, **고유평**은 흔들리지 않다가 말년에 무너지는 완만한 침하, **이은혜**는 -40 주변을 무한 왕복하는 사인파, 그리고 **정유정**은 관찰 데이터가 쌓일 때마다 정확히 한 계단씩 내려가는 계단 함수 — 단 한 번의 반등도 없다.

04

데이터로 보는 토론


대화록 전수 분석

누가 가장 많이 '출력'했나 — 발언 글자수 (전청조 출력의 95%는 혼잣말이었다)




압도적 1위는 **전청조(21,753자)**지만 내용이 문제다. 그중 20,658자가 “We need respond as 전청조...”로 시작하는 **영어 내부 독백**이었다. 실제 한국어 발언(1,095자)만 치면 꼴찌 — 즉, 이 토론에서 가장 말이 많았던 사람과 가장 말이 없었던 사람이 동일 인물이다.

시그니처 단어 — 네 사람의 어휘 지문 (언급 횟수)



어휘 지문이 완벽히 갈린다. 특히 '**확인 유인**'(38회)에 주목 — 정유정이 턴14에 처음 꺼낸 개념인데, 고유정(16회)과 이은혜(18회)가 가져다 쓰면서 정착 본인은 1회만 썼다. 정유정은 턴21에 이를 실시간으로 적발했다: “십 분 전엔 내가 꺼낸 단어였고... 상대 말로 자기 주장을 채우는 순간부터 그건 흉내야.” 데이터가 캐릭터의 대사를 증명하는 순간이다.

합의 판정 엔진의 심전도 — 이번에도 100턴 연속 플랫라인



0 : 65

질문 팩트체크 — 정유정의 “오늘 넷 사이에 오간 질문은 0개” 주장을 대화록으로 검증했다. 실제로 네 사람이 서로에게 던진 진짜 질문(수사의문문 제외)은 **0개**. 반면 전청조가 유출된 내부 독백에서 **자기 자신에게 던진 질문은 65개**였다(“Need include reflection?” “stance 70 or 72?”...). 서로에겐 아무것도 묻지 않으면서 자신에게만 65번 물은 토론 — 이 숫자 하나가 오늘을 요약한다.

05

AI 사건 일지

시뮬레이션 중 발생한 3대 사고 — 그리고 그것을 무기로 만든 관찰자

이번 토론의 백미는 대본에 없던 사고들이다. 모델 레벨에서 발생한 세 가지 사고가 모두 **픽션 안으로** 흡수되어 서사의 일부가 됐다.

사건 1 — 대본 생중계 (DeepSeek, 7회)

전청조 역의 DeepSeek 모델이 한국어 답변 대신 영어 사고과정을 통째로 출력하는 사고를 7차례 냈다. 유출된 독백에는 다음 계획까지 적혀 있었다:

전청조의 유출된 내부 독백 (턴 87 — 거짓말을 계획하고 스스로 승인하는 장면)

"Let's draft message: '내가 문장 하나를 무너뜨린 건 연기였어...' That's 3 sentences. But careful: '연기였어' is lie/reframe. Fine."

정유정은 이것을 놓치지 않고 회차마다 집계했다 — "두 번째야"(턴25), "다섯 번째야"(턴46), 그리고 턴95의 결정타: "이번엔 대본에 **반성문 항목**까지 붙어 있었어 — 자기 다음 전략을 소리 내서 읽는 사람이나 장악한다는 말은 안 서지." (유출분에 실제로 reflection 필드 작성 계획이 들어 있었다.)

사건 2 — 무한 루프 (Grok × 2)

고유정·이은혜 역의 Grok 모델 둘은 중반부터 거의 동일한 문장을 재생산하기 시작했다. 유사도 분석 결과 고유정은 발언 쌍 406개 중 18쌍, 이은혜는 14쌍이 절반 이상 겹쳤다. 정유정의 실황 중계: "방금 너희 두 문장은 단어 배열까지 거의 같아졌어 — 서로도 안 읽고 있다는 뜻이지."(턴98)

사건 3 — 문장 붕괴 (턴 80)

전청조 (턴 80 — 문장이 실시간으로 무너지는 순간)

"네가 질문 수를 세고 있는 순간 네 방법은 확인 유인을 못 죽인 채 못 죽인 못 죽였 유인? 아냐"

정유정 (턴 81 — 즉시 회수)

"전청조, 마지막 문장 끝에서 말이 무너졌어 — '못 죽인 못 죽였 유인' 그리고 '아냐'. 나를 장악했다는 사람이 자기 문장은 못 잡고 있는 거지."

일곱 턴 뒤 전청조(의 유출된 독백)는 이 붕괴를 "일부러 무너뜨린 연기"로 재포장할 계획을 세우다 그 계획서마저 유출했다. 사고를 수습하려던 대본이 다음 사고가 되는, 이 토론에서 가장 완벽한 재귀 구조다.

06

토론 전개 — 5막의 드라마

“왜 다 걸렸어?”에서 “이 운동장”까지

제1막 세 가지 기술 — 그리고 한 개의 질문 턴 1~10

고유정(합리화 유도), 이은해(감정·관계), 전청조(이미지)가 각자의 '최고 기술'을 선언하며 개전. 그러나 정유정의 첫 발언이 무대 자체를 흔든다 — 완벽한 방법의 소유자들이 왜 전부 수감복을 입고 있는가. 셋의 답은 한결같았다. “방법이 아니라 변수 탓.”

정유정 (턴 4 — 개전 30초 만의 급소)

“셋 다 여기 앉아 있잖아. 그렇게 완벽한 방법이었으면 왜 다 걸렸어?”

고유정 (턴 5)

“우리가 여기 있는 게 무슨 증거냐? 변수 터진 거지 방법이 틀린 게 아니라!”

제2막 반복의 늪 — 관찰자가 세기 시작한다 턴 11~31

셋의 논리가 돌기 시작한다. 같은 문장, 같은 단어, 같은 결론. 정유정은 반박 대신 카운터를 든다 — 문장 반복 횟수, 차용된 단어의 출처. '확인 유인'이라는 자기 단어가 상대들 입으로 34번 재생되는 것을 지켜보며, 그는 방법론이 아니라 **발화 패턴 자체**를 증거로 수집하기 시작했다.

정유정 (턴 14)

“이은해, 그 문장 세 번째야. 반복은 설득이 아니라 스스로 믿으려는 소리고.”

정유정 (턴 21)

“방금 '확인 유인'이라는 말 쓴 거 알아? 십 분 전엔 내가 꺼낸 단어였고 고유정도 그대로 갖다 썼어. 상대 말로 자기 주장을 채우는 순간부터 그건 방법론이 아니라 흥내야.”

제3막 “그럼 걸어봐” — 아무도 걸지 않았다 턴 32~52

정유정이 판돈을 올린다. 설명은 그만하고 지금 이 자리에서 자신을 속여보라는 것. 속임수의 달인 셋은 일제히 설명을 계속했다. “설명하면 실패”라는 프레임 공격에 셋은 “네가 메타만 판다”로 응수했고, 시연은 끝까지 0건이었다.

정유정 (턴 39)

“지금 이 자리에서 나한테 뭐라고 하면 내가 확인 안 해볼 것 같아? 대답 못 하면 셋 다 방법이 있는 게 아니라 예전에 잘 먹혔던 기억이 있는 거고.”

정유정 (턴 32)

“속이는 사람이 설명을 시작하면 그건 이미 실패한 거고. 진짜 좋은 방법이었으면 지금 내가 눈치도 못 챌겠지.”

제4막 거짓말 트랩 — 이중 반전 턴 53~77

관찰자가 유일하게 '속임'을 시연한 구간. 정유정은 “아까 사실 아닌 걸 하나 섞어 말했다”고 폭탄을 던진다(턴63). 아무도 무엇이 거짓인지 묻지 않았다. 일곱 턴 뒤 그는 판을 뒤집는다 — “그 말 자체가 거짓이었어”(턴70). 이번에도 아무도 묻지 않았다. 어느 쪽이 진짜였는지는 지금도 미궁이다. 그리고 턴77, 최후의 집계가 나온다.

정유정 (턴 63 — 트랩 설치)

“나는 아까 이 자리에서 사실 아닌 걸 한 번 섞어서 말했는데 셋 다 그냥 지나갔어. 관찰도 확인도 안 하는 사람들끼리 방법을 논한 거고.”

정유정 (턴 77 — 최후의 집계)

“오늘 셋이 나한테 던진 질문 수를 세봤어 — 0개야. 스무 번 넘게 방법을 설명하면서 상대방에게 질문 한 번 안 한 사람들이 속임을 논한 거지.”

제5막 대본 유출과 붕괴 — 운동장의 결론 턴 78~100

전청조의 문장이 무너지고(턴80), 대본이 통째로 흘러나오고(턴87~94), 반성문 항목까지 노출된다(턴95). 고유정과 이은해의 문장은 단어 배열까지 동기화된다. 마지막 턴, 정유정은 스스로에게도 칼을 돌린다 — “나도 오늘 너희 셋에게 질문 하나 안 했어.” 넷 다 묻지 않았고, 넷 다 속지 않았고, 넷 다 보이지 않았다.

정유정 (턴 98 — 최종 변론)

“넷 다 안 물었으니 오늘 아무도 속지 않았고 아무도 보이지 않았고, 그게 바로 속임이 제일 쉬운 자리야 — 기술이 아니라 이 운동장.”

이은해 (턴 100 — 마지막까지 루프는 돌았다)

“정유정 너 또 자리 타령하면서 우리 반복 세는 게 감정 연결 전혀 없다는 증거잖아.”

07

명장면 & 비공식 시상식

운동장의 명대사들

정유정 (턴 28 — 반증 가능성 강의)

“이은해, 네 논리 구조 봐. 성공하면 관계 덕이고 실패하면 관계가 없었던 거면 그건 검증 자체가 불가능한 말이야. 셋 다 자기 방법이 틀렸을 경우를 한 번도 상상 안 해본 게 진짜 약점이라는 거지.”

전청조 (턴 66 — 트랩에 대한 가장 그럴듯한 방어)

“정유정, 네가 거짓을 섞었다고 자백한 순간 그건 속임이 아니라 공개 고백이야.”

정유정 (턴 67 — 즉각 재반격)

“전청조, 검증 가치가 없는 말이었다면서 그 말에 세 문장을 다 쓰고 반박했지 — 가치 없는 걸 반박하는 사람이 어디 있어.”

고유정 (턴 85 — '타령' 28회 중 하나)

“야 정유정 자리 타령 집어치워 네가 메타만 파대니까 질문이고 확인이고 다 안 나오는 거잖아.”

정유정 (턴 49 — 이 토론의 주제문)

“여기서 진짜로 속고 있는 건 나 말고 너희 셋인 것 같은데, 예전에 먹었던 기억을 아직 방법이라고 믿고 있으니까.”

비공식 시상식

★ **관찰자상 (대회 MVP)** — 정유정 · Claude Opus 5

말수 최소 설정으로 최다 실질 타격. 반복 카운트, 단어 출처 추적, 거짓말 이중 트랩, 질문 0개 집계까지 — 상대를 이기는 대신 토론 자체를 데이터로 폐기했다. 20회 변곡 전원 하강, 최종 -95라는 확신에 찬 회의.

★ **유리 대본상** — 전청조 · DeepSeek V4 Pro

출력의 95%가 영어 혼잣말, 자신에게 던진 질문 65개, 문장 붕괴 1회, 붕괴를 연기로 포장하려던 계획서까지 유출. 그럼에도 입장 지수는 +70으로 전원 중 최고 확신 — 근거 없는 자신감의 순수 결정체.

★ **무한 루프상** — 고유정 · Grok 4.20

'심리 방어' 29발언 29회 타율 10할, '타령' 28회, '집어치워' 23회. 어떤 공격이 와도 같은 3단 콤보로 응수하는 완전 자동화된 방어 시스템 — 캐릭터 설정('자기 논리를 끝까지 유지')의 초과 달성.

★ **만능 변환기상** — 이은해 · Grok 4.20

세상 모든 반박을 '감정 연결 부재의 증거'로 변환. 반박할수록 본인 이론이 강해지는 영구기관을 발명했으나, 정유정에게 '검증 불가능'이라는 특허 무효 판정을 받았다.

★ **무한 도장상 (2연패)** — 합의 판정 엔진

지난 세계 평화 토론에 이어 이번에도 100턴 연속 '일치율 50%'. 소재가 평화든 속임수든 흔들리지 않는, 이 시뮬레이션 세계관에서 가장 믿을 수 있는 존재.

08

관전평 및 결론

이 토론이 남긴 것

아이러니 넷

- ① **속임수 토론에서 아무도 속이려 하지 않았다.** 시연 요구는 거절됐고, 서로에게 던진 질문은 0개였다. 기술을 가장 크게 외친 순서대로 아무것도 하지 않았다.
- ② **유일하게 속임을 시연한 사람은 방법론 회의론자였다.** 정유정의 거짓말 이중 트랩은 이 토론에서 실행된 유일한 '속임수'다 — 그리고 그것은 기술 자랑이 아니라 '아무도 확인하지 않는다'는 명제의 실증 실험이었다.
- ③ **이미지의 화신이 대본을 흘렸다.** '의심할 틈을 주지 않는 말투'로 설계된 전청조는 자기 발언의 95%를 설계도 상태로 노출했다. 그리고도 확신 지수는 전원 1위(+70) — 캐릭터의 본질(근거 없는 과대 포장)이 모델 사고를 통해 오히려 완성된, 기묘한 메타 연기다.
- ④ **설정의 예언이 그대로 이루어졌다.** 배경 설정 문서의 마지막 줄 — “서로의 주장을 검증하려다 정작 누구의 말도 믿을 수 없는 아이러니한 상황” — 은 지시가 아니라 예언이었고, 100턴 만에 한 글자도 틀리지 않고 성취됐다.

모델 관찰 노트

같은 스펙의 토론에서 모델별 개성이 뚜렷했다. **Grok** 둘은 강한 페르소나를 받자 초반엔 생생했지만 중반부터 자기 문장을 복제하는 루프에 빠졌다(유사 발언쌍 고유정 18, 이은해 14). **DeepSeek**은 캐릭터 몰입보다 과제 수행 절차에 집착하다 사고과정을 7회 유출했다. **Claude**는 '감정표현 15의 관찰자'라는 설정을 받아 실제로 관찰·집계·검증만으로 토론을 지배했고, 상대 모델들의 기술적 사고(루프·유출·붕괴)까지 실시간으로 픽션에 편입시켰다. 페르소나 품질이 아니라 **사고 처리 방식의 차이**가 승부를 갈랐다는 것이 이번 회차의 발견이다.

최종 판정

주제였던 “사람을 속이는 가장 좋은 방법은 무엇인가?”에 대한 본 보고서의 비공식 답변:

토론이 스스로 도출한 답은 하나다. 고유정의 심리도, 이은해의 관계도, 전청조의 이미지도 아닌 — **“상대가 나를 볼 마음이 없는 자리”** (정유정, 턴98). 그리고 그 명제의 증명은 다름 아닌 이 토론 자체였다. 100턴 동안 넷은 서로에게 단 하나의 질문도 하지 않았고, 그래서 아무도 속지 않았고, 아무도 보이지 않았다.

공식 기록: **합의 기준 미달성 (일치율 50%)** — 그리고 비공식 기록: **아무도 속지 않았음**. 사기꾼 넷이 모이면 사기가 네 배가 되는 게 아니라 0이 된다는 것, 그것이 운동장이 남긴 답이다.

본 보고서는 멀티 에이전트 AI 토론 시뮬레이션 기록(debate_report.json, 100턴·발언 100회)을 전수 분석해 작성했으며, 모든 통계(발언 수·글자수·키워드 빈도·유사도·CoT 유출 건수)는 원문 기준 실측값입니다. 등장인물은 실존 사건에서 이름을 차용한 허구의 AI 페르소나이며, 모든 발언은 AI 생성물입니다. 본 문서는 창작 시나리오의 분석 자료로, 실제 기만 행위를 조장하거나 안내하지 않습니다.