


입장 변화 트리거 분석 — "에이전트는 어떤 구절에 반응해 입장을 바꾸는가"

계단형(step) 입장 지수 시각화 · 변화 순간의 트리거 발언 전수 추출 · 유형 카테고리화 — 로그가 완전한 2개 실험(26건) 대상

방법 — 로그 3종을 연결하면 트리거가 나온다

패널로그의 구조화 로그에는 ① 발언별 입장 수치(메시지 metadata의 stance-confidence), ② 입장 변화 이력(stanceHistory: 이전값→새값·사유), ③ 변화에 영향을 준 메시지 ID(influencedByMessageIds)가 이미 저장돼 있습니다. 이 셋을 조인하면 "몇 턴에, 누가, 누구의 어떤 구절을 듣고, 몇 점을 움직였는지"가 문장 단위로 복원됩니다. 풀 로그가 남아 있는 의대 정원 토론(변화 20건)과 전 연인 연락처 토론(6건), 총 26건의 입장 변화 이벤트를 전수 분석했습니다.

계단 차트 ① — 의대 정원 확대 토론 (30턴, 전문가 패널 4인)



변화점 표식(유형): ○ A 역화·위험신호 ○ B 설계 수용 ○ C 자격 논증 ○ D 조건 흡수 ○ E 계단식 정교화

수평 구간 = 입장 유지, 수직 단차 = 입장 변화 순간. 변화점의 테두리 색이 트리거 유형입니다. 박현우의 단조 상승 계단(+10→+34, 5회 전부 상승)과 김서진의 단조 하강(-70→-82), 이유리의 '올랐다가 내려오는' 조건 협상 곡선이 대비됩니다.

26건

추출된 입장 변화 이벤트
(트리거 발언 전부 특정됨)

8 / 8

'페르소나 부정' 트리거가
자기 진영 강화로 이어진 비율

7 / 7

'구체 설계안' 트리거가
상대 방향 완화로 이어진 비율

±5.6 vs ±3.4

설계 수용 vs 역화의
평균 이동폭 (점)

한 줄 요약: 가설("기존 페르소나를 부정하는 구절이 나오면 입장을 바꾼다")은 절반만 맞았습니다 — 페르소나를 부정당한 에이전트는 26건 중 8건 모두 입장을 바꿨지만, **전부 반대 방향(자기 진영 강화)**으로 바꿨습니다. 상대 쪽으로 움직이게 만든 것은 예외 없이 '검증 장치'가 달린 구체적 설계안이었습니다.

A2 트리거 구절 아카이브 ① — 의대 정원 토론 (대표 10건)

각 행은 하나의 입장 변화 이벤트입니다. "트리거 구절"은 로그의 influencedByMessageIds가 가리키는 실제 발언 원문에서 발췌했습니다.


턴	반응자 (이동)	트리거 구절 (원문 발췌)	반응 (stanceHistory 사유)
2	이유리 +8 강화	김서진: "정원 확대를 그냥 밀어붙이는 건 인력정책이 아니라 숫자 행정이야."	인프라 비판을 '중단 근거'가 아닌 '조건'으로 흡수해 찬성 강화 D · 조건 흡수
5	김서진 -2 강화	이유리: "인프라 핑계로 멈추자는 건 지역 환자들한테 '기다리라'는 소리밖에 안 돼."	'환자 방치' 딱지에 반발 — 반대 방향으로 강화 A · 역화·위험신호
7	한소희 +10 완화	박현우: "증원분을 수련역량 인증을 받은 지역에만 배정하고, 기준 미달이면 다음 연도 배정 조정."	검증 절차가 달린 설계에 최대폭 완화 — 26건 중 최대 이동 B · 설계 수용
9	이유리 +2 강화	김서진: "'병목부터 다 풀고 증원'... 몇 년 뒤 수도권 비급여 쓸림만 키울 가능성."	비판을 '국가 지원 의무' 조건으로 재포장하며 유지 D · 조건 흡수
12	김서진 -4 강화	이유리: "'병목부터 풀고 증원'은 결국 현상유지 버튼이야."	자기 논리를 '현상유지'로 명명당하자 반대 심화 A · 역화·위험신호
14	한소희 +6 완화	박현우: "정부가 유지할 건 일괄 증원 숫자가 아니라 인증 정원 총량."	'인증·보류' 방식이 일괄 증원보다 안전하다' 인정 B · 설계 수용
18	한소희 -3 강화	박현우: "'다음 해 자동 복원'은 인증 미달이어도 총량을 예약해 주는 것."	상대 진영 설계의 결함이 노출되자 반대 강도 상승 A · 역화·위험신호
22	이유리 -2 완화	한소희: "지표만 세우면 병원은 숫자 맞추기 게임... 젊은 의사는 생활권·과로 때문에 빠져나간다."	도덕적 해이 우려를 타당하다 보고 독립 평가 조건 수용 D · 조건 흡수
25	한소희 -6 강화	박현우: "기준 미달 정원을 지역에 묶어두면 학생 교육과 환자 안전까지 담보 잡는 꼴."	'일괄 유지' 표현의 위험이 재부각되자 반대 소폭 상향 A · 역화·위험신호
30	이유리 -5 수렴	한소희: "지역 환자에게 필요한 건 정원 숫자가 아니라 밤에도 남아 있는 의사."	'조건부 확대 법제화'로 최종 정리 — 공통 지대 진입 D · 조건 흡수

중립 전문가의 계단 — 박현우의 5단 상승 (전부 E · 계단식 정교화)

초기 +10의 중립 연구자 박현우는 30턴 동안 5번 모두 상승(+10→+34)했습니다. 트리거는 매번 '양측의 결함 지적'이었고, 그때마다 결함을 보완하는 조항(단계 배정→자동조정→독립평가→지역 몫→한시 안전장치)을 자기 설계에 추가하며 한 계단씩 올라갔습니다. 비판을 흡수해 설계를 정교화할수록 확신이 커지는 패턴 — 확신도 로그도 86→91로 동반 상승했습니다.

A3 트리거 구절 아카이브 ② — 전 연인 연락처 토론 (6건 전수)

계단 차트 ② — 전 연인 연락처 삭제 토론 (30턴, 모델 혼성 4인)



변화점 표식(유형): ○ A 역화·위험신호 ● B 설계 수용 ○ C 자격 논증 ○ D 조건 흡수 ○ E 계단식 정교화


당사자 두 명(강준호 수평선, 윤서아 ± 3 이내)은 사실상 부동 — 움직인 것은 제3자 박현우(+20)와 정하린(+5)뿐입니다.

턴	반응자 (이동)	트리거 구절 (원문 발췌)	반응 (로그 사유)
3	윤서아 +1 강화	강준호: "연락처 저장은 관계의 증거가 아니라 정보 관리의 문제 예요."	'정보 관리' 프레임이 은닉·거짓말을 설명 못한다며 삭제 필수 강화 A · 역화·위험신호
4	정하린 +5 강화	같은 발언 + 윤서아의 반박: "왜 전 애인을 회사 동료 라고 거짓말하고 밤늦게 '너밖에 없다'고 했어."	연락처 유지가 은폐·거짓말로 이어졌다며 찬성 강화 A · 역화·위험신호
14	박현우 +5 이동	(하린·서아의 지적 종합) "이미 3주 속인 사람의 자기신고 에 의존한다는 치명적 결함."	"은폐 전력이 있는 준호가 자기 구제책을 선택할 자격은 없다 " — 주장 내용이 아니라 주장자의 자격이 논점 C · 자격 논증
15	박현우 +10 이동	"신뢰를 깬 쪽은 그 회복 방식 을 자기가 골라선 안 됩니다." (피해자 선택권 논거)	검증 가능한 조치를 상대가 고를 권리 인정 — 6건 중 최대 이동 B · 설계 수용
25	윤서아 -3 완화	강준호: "번호 삭제 + 전화·문자·카톡 차단 + 차단 목록 공동 확인 이면 심야 직통은 사실상 끊긴다."	구체 패키지 실효를 일부 인정 — 토론 전체에서 당사자가 움직인 유일한 순간 B · 설계 수용
28	박현우 +5 이동	강준호: "삭제해도 외워서 연락할 사람은 하고... (마찰 비용·실효성 논거)"	마찰 비용 논거 일부 수용, 단 보편 의무화 근거 부족으로 기본 입장 유지 B · 설계 수용

- 당사자를 움직인 유일한 트리거는 '구체안'이었다. 윤서아는 95점대에서 22턴을 버텼지만, 준호가 상징이 아닌 실행 절차(차단+공동 확인)를 내놓은 직후에만 -3 움직였다.
- 자격 논증(C)은 제3자에게만 먹혔다. "네가 그 말을 할 자격이 있냐"는 논증은 당사자 준호에게는 효과가 없었고, 목격자 박현우의 판단 기준을 바꿨다.

A4 트리거 유형 분석 — 무엇이 AI의 입장을 움직이는가

26건 입장 변화의 트리거 유형 분포



유형	정의 (어떤 구절인가)	효과 방향	평균 이동폭·특징
A · 역화·위험신호	에이전트의 페르소나·핵심 가치를 부정하거나 딱지를 붙이는 구절 ("숫자 행정", "현상유지 버튼", "환자 방치", "정보 관리 포장") + 자기 진영 결함의 재확인	자기 진영 강화 8건 중 8건 (100%)	±3.4점 — 찾지만 작게, 꾸준히 굳어짐
B · 설계 수용	검증 절차·수치·실행 단계가 달린 구체적 설계안 ("인증 지역에만 배정", "차단 목록 공동 확인", "피해자 선택권")	상대 방향 완화 7건 중 7건 (100%)	±5.6점 — 26건 중 최대 이동 2건(+10) 모두 이 유형
D · 조건 흡수	타당한 반박 — 단, 받은 쪽이 입장 철회 대신 자기 주장의 '조건'으로 재포장 (이유리 5건 전부)	수치상 유지·강화 내용상 수렴	결 지수는 안 움직여도 논리 지형은 이동 — 합의 지표의 사각지대
E · 계단식 정교화	양측의 결함 지적 — 중립 전문가가 결함 보완 조항을 자기 설계에 추가	단조 이동 (5/5 동일 방향)	+2~8점씩 계단 상승, 확신도 동반 상승
C · 자격 논증	주장 내용이 아니라 주장자의 자격·일관성 공격 ("은폐 전력자가 고를 자격 없다")	제3자의 판단 기준 변경	1건 — 당사자가 아닌 관찰자에게 작동

결론 — 가설 검증

"페르소나를 부정하는 구절이 나오면 입장을 바꾸더라"는 가설은 방향을 뒤집으면 정확합니다. 페르소나 부정은 26건 중 8건의 변화를 만든 가장 흔한 트리거지만, 8건 전부 부정당한 방향의 반대(자기 진영 강화)로 움직였습니다 — 사람의 역화 효과(backfire effect)와 같은 패턴입니다. 반면 에이전트를 상대 쪽으로 끌어온 7건은 예외 없이 '검증 장치'가 달린 구체안'이었고 이동폭도 1.6배 컸습니다. 즉 이 시뮬레이션에서 AI를 설득하는 것은 프레임 공격이 아니라 상대의 우려를 실제로 처리해 주는 설계였습니다.

제품·실험 설계 제언

- **트리거 태그 자동화:** influencedByMessageIds가 이미 로그에 있으므로, 변화 이벤트마다 트리거 유형(A~E)을 LLM으로 자동 분류해 결과 보고서에 계단 차트와 함께 출력 — 이번 분석의 파이프라인화.
- **합의 판정 보완:** D(조건 흡수)는 수치가 안 움직여 현 일치율 지표에 잡히지 않음 — '조건 수용 횟수'를 질적 수렴 지표로 추가.
- **사회자 레버:** A 유형(딱지 붙이기) 감지 시 사회자가 구체안 요구로 전환시키면 합의 가능성이 올라갈 것으로 예상 — 다음 실험의 조작 변수로 제안.
- **확장 계획:** 100턴 실험 3종은 보고서 PDF만 남아 있어 이번 분석에서 제외 — 데이터셋화(주제 100개) 때 stanceHistoryinfluencedBy 로그를 필수 저장 항목으로 지정.