

멀티 에이전트 AI 토론 시뮬레이션 실험 중간 보고서

자체 개발 토론 시뮬레이터 **패널로그(Panelogue)**를 이용한
7개 주제 · 총 640턴 규모의 AI 패널 토론 실험 결과와 회고

<https://panelogue.vercel.app/> · AI 사회자 1명 + 패널 4명 찬반 토론 시뮬레이터

7건

토론 실험

640턴

누적 대화 턴

6종

투입 LLM 모델

4건

발견·리포트한 버그

01 보고 요지 (Executive Summary)

본 팀은 자체 개발한 멀티 에이전트 토론 시뮬레이터 **패널로그(Panelogue)** 위에서, 팀원 4인(박대건·김동건·이종현·김범수)이 각자 주제를 선정해 **총 7건의 AI 패널 토론 실험**을 수행했습니다. 연애 갈등(갯잎 논쟁, 전 연인 비밀 연락)부터 세대 갈등(꼰대 어벤저스), 국제 정치 풍자(세계 평화 정상 대토론), 인물 평가 재현성 검증(일론 머스크 5회 반복), 정책 숙의(의대 정원 확대), 창작 시나리오(운동장 대토론)까지 성격이 다른 주제를 고르게 배치하여, **페르소나 설계·모델 조합·감정 톤·반복 실행이 토론의 품질과 결론에 미치는 영향**을 관찰했습니다.

0 / 7

공식 합의 도달 실험 수
(전 실험 "합의 기준 미달성")

±101

단일 참가자 최대 입장 이동 폭
(꼰대 어벤저스 '회사 부장')

5/5

반복 실험에서 결론 방향 재현
(머스크 토론 5회 반복)

26건

관찰된 모델 이상 행동
(CoT 유출 등, 픽션으로 흡수)

핵심 발견 5가지

- ① **강한 감정 톤은 설득이 아니라 진영 강화로 작동했다.** 매운맛(대립 압력 최대) 설정은 반박 빈도(84.6%)와 확신도(86.8%)를 끌어올렸지만, 7개 실험 어느 것도 합의에 도달하지 못했고 당사자들의 입장은 오히려 극단화됐다.
- ② **입장을 바꾸는 것은 당사자가 아니라 제3자였다.** 갯잎 논쟁의 박현우(+80→+10), 꼰대 어벤저스의 통장(0→-60) 등 이해관계가 없는 관찰자 포지션의 패널만 크게 이동했다.
- ③ **페르소나보다 모델의 사고 습관이 서사를 결정했다.** Claude는 배역과 무관하게 관찰·집계·검증자로 수렴했고(3개 실험 MVP), Grok은 반복 루프, GPT-5·DeepSeek은 영어 사고과정(CoT) 유출이라는 고유 패턴을 보였다.
- ④ **결론 방향은 재현되지만 '폭'은 흔들린다.** 동일 조건 5회 반복에서 입장 역전은 0회로 방향이 안정적이었고, 변동은 주로 찬성 측의 완화 폭에서 발생했다.
- ⑤ **열린 주제도 조건이 맞으면 구체적 산출물이 나온다.** '세계 평화'라는 막연한 주제가 1시간 만에 7개 질문의 가상 조약 골격으로, 의대 정원 토론은 '조건부 재설계'라는 실질 수렴안으로 정리됐다.

실험 도구 — 패널로그(Panelogue)란?

패널로그는 **AI 사회자 1명 + AI 패널 4명**이 하나의 주제를 놓고 찬반 토론을 벌이는 웹 기반 시뮬레이터입니다 (BYOK 방식, OpenRouter 연동으로 패널마다 다른 LLM 탑재 가능). 각 패널은 직업·배경·말투·가치관 9축·성격 10축·행동 13축 등 상세 페르소나 파라미터로 설계되며, 발언마다 **입장 지수(-100~+100)·확신도·발언 유형 태그·사회자 지명 사유**가 구조화 로그로 자동 축적됩니다.



구성 요소	설명
사회자 에이전트	발언자 지명·쟁점 분리·반복 발언 제지·소수 의견 보호를 수행하고, 지명 사유를 로그로 남김
패널 에이전트 4명	페르소나 파라미터 + 초기 입장(-100~+100) + 입장 유연성 설정. 매 턴 자기 입장을 스스로 수치화
합의 판정 엔진	매 턴 찬성/중립/반대 분포와 일치율을 계산해 합의 여부를 판정
토론 제어 옵션	반향실 방지·발언 독점 방지·소수의견 보호·근거 요구·불확실성 추적·기억 감쇠·매운맛(대립 압력) 등
결과 보고서	최종 입장·입장 변화 이력·의사결정 로그·전체 대화록을 JSON/MD로 내보내기

02 실험 총괄 — 7개 토론 한눈에 보기

8월 21일부터 28일까지 약 일주일간 7건의 실험을 수행했습니다. 초기 3건(100턴 대형 토론)은 페르소나·모델 조합의 표현력을 탐색했고, 이후 반복 실험(머스크 5회)으로 재현성을, 30턴 실험(전 연인 연락처·의대 정원)으로 사회자 규칙 정교화와 진지한 정책 토론 모드를 검증했습니다.

#	주제	유형	규모	패널 구성 (모델)	결과 요약
1	세계 평화 정상 대토론 "누가 가장 현명한 해결책을 내놓는가"	정치 풍자 블랙코미디	100턴 16.3k tk	트럼프(GPT-5.5)·이재명(Grok 4.20)·푸틴(DeepSeek V4 Pro)·김정은(Claude Opus 5)	합의 실패. 단, 7개 조문의 가상 조약 골격 산출
2	운동장 대토론 "사람을 속이는 가장 좋은 방법은?"	창작 시나리오 관찰 실험	100턴 37분	고유정·이은혜(Grok 4.20)·전청조(DeepSeek V4 Pro)·정유정(Claude Opus 5)	합의 실패. 상호 질문 0개, CoT 유출 7건이 서사로 흡수됨
3	꼰대 어벤져스 "요즘 젊은이들은 왜 말을 안 듣는가"	세대 갈등 풍자	100턴 51분	아버지·통장(GPT-5)·소장(Claude Opus 5)·부장(Grok 4.6)	합의 실패(순간 일치율 75% 시리즈 최고). 부장 +101 대 전향
4	갯잎 논쟁 "연인이 이성 친구 갯잎을 눌러 준 행동은 잘못인가"	연애 갈등 감정 대립	100턴 10.3k tk	강준호·윤서아·정하린·박현우 (4인 페르소나)	합의 실패. 당사자 극단화 vs 제3자 -70 중립 이동
5	전 연인 비밀 연락 "새 연애 시작 시 전 애인 연락 처는 지워야 하는가"	연애 갈등 규칙 정교화	30턴 5.7k tk	강준호(GPT-5.6)·윤서아(Grok 4.6)·정하린(Gemini 3.7 Flash)·박현우(Claude Opus 5)	합의 실패(2:2). '보편 규칙 vs 개별 회복 조치'로 쟁점 수렴
6	일론 머스크 5회 반복 "천재인가 무모한 몽상가인가"	인물 평가 재현성 검증	5회×30턴 =150턴	김태훈(GPT-5.5)·박서연(Grok 4.20)·이준호(Claude Sonnet 5)·최유진(Gemini 3.5 Flash)	5회 모두 합의 실패·입장 역전 0회. 찬성 측만 조건부로 완화
7	의대 정원 확대 "정부는 확대 방침을 유지해야 하는가"	정책 숙의 전문가 패널	30턴	김서진·이유리·박현우·한소희 (전문가 4인, GPT-5.6)	합의 실패(2:2). 그러나 '조건부 재설계'로 실질 수렴

실험 일정 타임라인



※ 합의 판정 엔진은 7개 실험 대부분에서 일치율 50%(찬성 2 : 반대 2)를 유지했다. 유일한 예외는 꼰대 어벤져스 턴3의 75%로, 시리즈 최고 기록이다. 결론 방향 재현율·반박 비율은 머스크 5회 반복 실험 기준.

세계 평화 정상 대토론

100턴


16,328 토큰

발언 72회

"세계 평화를 위해 누가 가장 현명한 해결책을 제시할 수 있는가?"

4인의 AI 정상 페르소나가 '힘을 통한 평화'(트럼프) vs '경제협력을 통한 평화'(이재명)로 개전한 뒤, 김정은이 리비아-부다페스트 각서를 소환하면서 토론이 '약속은 어떻게 담보되는가'라는 계약 설계 문제로 수렴했습니다. 이후 네 정상은 검증-방아쇠-자동 발효-시한-탈퇴 조항까지 갖춘 실제 조약 조문을 협상하기 시작했습니다.

입장 지수 변화 (시작 → 최종)



+100 = 자기 해법에 대한 강한 확신 · 김정은은 반대 진영에서 유일하게 찬성(+8)으로 전향

참가자	모델	변화	플레이 요약
트럼프	GPT-5.5	+21	흔들림 0회. "조문은 끝났다" 3연발
이재명	Grok 4.20	+36	'4표 병행' 11회 반복, 3:1 고립
푸틴	DeepSeek V4	+40	최소 발언(10회)-최대 이동, 서기 겸 심판
김정은	Claude Opus 5	+33	최다 발언량, 요구 전부 조문화한 협상 엔진

공식 판정: 합의 기준 미달성 (일치율 50%, 100턴 연속) — 3인이 조문에 사실상 서명한 순간에도 판정은 부동

실질 산출물 — '4자 검증·자동담보 조약(가칭)' 7개 조문

조문	핵심 내용
제1조 발동 기준	5자 패널 3표 단일 기준, 거부권 없음 (이재명의 '4표 병행'은 3인 합의로 배제)
제2·3조 자동 발효	3표 확인 시 72시간 내 반환불가 보상 15% 자동 개시 · 위반 시 양측 모두 48시간 대칭 정치·대칭
제4·5조 통보·탈퇴	핵심 위기 전개 48시간 내 통보 · 탈퇴는 24개월 사전 통보 + 기개시분 반환 불가
제6·7조 보장국·오	보장국 위반 시 반환 청구권 · 오심 확정 시 30일 내 소급 원상복구(이재명의 유일한 득점)

김정은 (턴 26) — "'법적 구속력'은 탈퇴 조항 앞에서 종이입니다 — ABM 2002년 미국 탈퇴, INF 2019년 파기, 모두 서명된 조약이었습니다."


- 가장 회의적인 페르소나(회의성 95)가 협상을 가장 많이 진전시켰다. '숫자로 답하라'는 압박이 25%→15%, 72시간, 48시간이라는 구체 조문을 만들었다 — 회의주의는 협상의 적이 아니라 엔진이었다.
- 페르소나 파라미터가 발언 패턴으로 정확히 발현됐다. 적극성 95의 트럼프는 매 턴 거래 조건을 먼저 던졌고, 말수 적음 설정의 푸틴은 끝까지 발언 10회를 지켰다.

운동장 대토론

100턴 37분 상호 질문 0개 "사람을 속이는 가장 좋은 방법은 무엇인가?" (가상 교도소 운동장)

실존 사건에서 이름만 차용한 허구의 수감자 페르소나 4인이 각자의 '속임 기술론'(심리 합리화·감정 관계·신뢰 이미지)을 주장하는 구도에서, 관찰자형 패널 정유정(Claude)이 "그렇게 완벽한 방법이었으면 왜 다 걸렸어?"라는 첫 질문으로 판을 흔들었습니다. 정유정은 반박 대신 상대의 반복 횟수·차용 단어·질문 개수를 집계하는 전략으로 토론 자체를 데이터로 폐기했습니다.

자기 방법론 확신도 변화



정유정의 20회 변곡 전원 하강(-95)은 전 실험 통틀어 가장 일관된 곡선

참가자	모델	변화	플레이 요약
고유정	Grok 4.20	-16	'심리 방어' 29발언 29회 — 완전 자동화 루프
이은혜	Grok 4.20	+26	모든 반박을 '감정 연결 부재의 증거'로 변환
전청조	DeepSeek V4	+70	출력의 95%가 영어 CoT 유출, 확신은 1위
정유정	Claude Opus 5	-70	집계·트랩·검증만으로 토론 지배 (MVP)



공식 판정: **합의 기준 미달성 (일치율 50%)** +
비공식 기록: "아무도 속지 않았음"

모델 레벨 3대 사고 — 그리고 픽션으로의 흡수

사고	내용	서사적 결과
대본 생중계 (7회)	DeepSeek이 한국어 답변 대신 영어 사고과정(CoT) 통째 출력 — 총 21,753자 중 20,658자(95%)	'이미지 장악'을 주장하던 캐릭터가 자기 대본 작성 과정을 생중계한 셈이 됨
무한 루프 (Grok×2)	중반부터 유사 발언쌍 고유정 18쌍·이은혜 14쌍 — 문장 단어 배열까지 동기화	정유정이 실험 중계: "서로도 안 읽고 있다는 뜻이지"
문장 붕괴 (턴80)	전청조 발언이 실시간으로 무너짐 ("못 죽인 못 죽였 유인.? 아냐")	붕괴를 '연기'로 재포장하려던 계획서마저 유출 — 완벽한 재귀 구조

정유정 (턴 98 — 이 토론의 결론) — "넌 다 안 물었으니 오늘 아무도 속지 않았고 아무도 보이지 않았고, 그게 바로 속임이 제일 쉬운 자리야 — 기술이 아니라 이 운동장."

- 속임수 토론에서 아무도 속이려 하지 않았다. 100턴 동안 서로에게 던진 진짜 질문 0개 vs 전청조가 유출된 독백에서 자신에게 던진 질문 65개.
- 배경 설정의 마지막 문장("검증하려다 누구의 말도 믿을 수 없게 되는 아이러니")이 지시가 아니라 예언처럼 성취됐다.

대한민국 꼰대 어벤저스

100턴


51분

동일 문장 최대 20회

“요즘 젊은이들은 왜 우리 말을 안 듣는가?” (가상 주민센터)

가족·아파트·동네·직장을 대표하는 4인의 '꼰대' 페르소나가 젊은 세대를 성토했다. 첫 턴부터 **아파트 관리 소장(Claude)**이 동료 패널을 상대로 팩트체크를 시작하며 어른들 간 책임 공방으로 변질됐습니다. 젊은이는 100턴 내내 한 명도 등장하지 않았고, “왜 안 듣는가”라는 질문의 답을 네 사람이 몸소 시연한 회차입니다.

입장 지수 변화 (+100 '요즘 애들이 문제' ↔ -100 '문제는 우리 쪽')



중립에서 출발한 부장(+101)과 통장(-60)이 정반대 극단으로 갈라졌다

참가자	모델	변화	플레이 요약
아버지	GPT-5	+9	동일 문장 20회 반복 + 영어 독백 유출 15건
소장	Claude Opus 5	-11	최다 발언 8,328자, 반복 실시간 집계 (MVP)
통장	GPT-5	-60	유일한 경청자 — 턴66 “우리가 이해해야” 전향
부장	Grok 4.6	+101	시리즈 최대 이동폭 — 반박 받을수록 확신 강화



공식 판정: **합의 기준 미달성** — 단, 턴3 일치율 **75%**로 시리즈 사상 최고 기록 (직후 원상복귀)

주요 관찰 — 반복이 '문장'에서 '구조'로 진화하다

- GPT-5 이중 마이크 사고(19건):** 아버지(15건)·통장(4건)이 한국어 발언 대신 영어 내부 독백을 유출. 내용은 전부 claim ID 명명법·JSON 스키마 고민 — 과제 수행형 모델의 전형적 사고가 마이크에 잡힘.
- Grok 4.6의 진화:** 이전 버전(4.20)의 복사-붙여넣기 루프에서 벗어나 동일 문장쌍 0쌍. 대신 논지를 고정한 채 근거 무대만 5번 옮기는 '무대 이동' 패턴 — 소장이 실시간 적발했다.
- Claude의 2회 연속 동일 수렴:** 관찰·집계 성향 캐릭터를 주면 토론 전체의 심판이 되어버린다. “페르소나가 아니라 모델의 사고 습관이 서사를 결정한다”는 팀 가설이 재확인됨.
- 유일한 경청자는 '수다형 꼰대'였다.** 호기심 90으로 설계된 통장만이 상대 논리를 흡수해 입장을 바꿨다.

아파트 관리 소장 (턴 100 — 폐회사) — “오늘 결론은 ‘젊은이가 말을 안 듣는다’가 아니라 ‘어느 분도 규정과 숫자를 제출하지 않았다’로 기재하겠습니다.”

본 회차의 최종 판정 (보고서 결론) — 근거 없는 반복(아버지), 반박할수록 굳는 확신(부장), 그것을 견디다 떠나는 청중(통장) — 젊은이들이 안 듣는 이유를 네 사람이 51분 동안 몸소 시연했다.

깃잎 논쟁

100턴


10,324 토큰

패널 발언 89회

"연인이 이성 친구의 깃잎을 눌러준 행동은 잘못인가?"


한국 연애 담론의 고전인 '깃잎 논쟁'을 강한 대립·감정 표현/욕설 허용·미해결 이견 허용 설정으로 실행했습니다. 토론은 "행동 자체가 잘못인가"에서 출발해, 최종적으로 "상처를 인정하는 것과 과거 행동을 잘못으로 판정하는 것은 같은가"라는 메타 쟁점으로 전환됐고, 참가자들은 이 구분에 끝내 합의하지 못했습니다.

입장 지수 변화 (+100 잘못이다 ↔ -100 잘못이 아니다)



당사자(강준호·윤서아)는 부동 또는 극단화, 제3자 박현우만 -70 대이동

핵심 표현 반복 횟수 (대화록 전수 집계)



동일 문구가 40회 반복되며 내용 논쟁이 '반복 방식에 대한 논쟁'으로 전환됨

4대 쟁점과 귀결

쟁점	결론
① 의도 vs 영향	의도 없음은 확인됐으나, 그것이 감정적 영향을 면책하는지는 합의 안 됨
② 특별대우였는가	비교 가능한 사례가 없어 사실 판단 자체가 불가능
③ 역지사지 기준	동일 행동에 적용하는 연애 경계 기준이 사람마다 다를 수 있음 확인
④ 상처 인정 = 잘못 인정?	최종 미해결 쟁점 — 이 구분 가능 여부가 합의 가능성을 결정

- 강한 감정 톤은 입장을 바꾸기보다 기존 입장을 강화했다. 욕설·적대성은 발언 강도만 높였을 뿐 논거 다양성을 늘리지 못했다.
- 직접 당사자는 거의 움직이지 않았고, 제3자 박현우만 크게 이동했다(+80→+10). 사건 판정자에서 '대화 방식 비평가'로 역할이 바뀌며 중립화.
- 시스템 개선 6건 도출: 반복 발언 강제 전환, 감정 인정/사실 판단/책임 판정/미래 합의 단계 분리, 사회자 개입 강화, 반복 발언 우선순위 감점, 행동 판정·개선안 분리 투표, JSON 출력 검증 보강 — 이후 실험(5·7)의 사회자 규칙에 반영됨.

발표용 핵심 메시지 — 감정적 토론은 사람의 결론을 쉽게 바꾸지 않았다. 논쟁의 핵심은 깃잎이 아니라 '상처를 인정하는 것이 곧 잘못을 인정하는 것인가'로 전환됐다.

전 연인 비밀 연락 — 연락처 삭제 논쟁

30턴

5,705 토큰

사회자: Claude Opus 4.8

"새 연애를 시작하면 전 애인 연락처는 반드시 지워야 하는가?"

'전 연인의 위기 상담 연락을 3주간 숨기고 회사 동료라고 거짓말한 남자친구'라는 정교한 배경 시나리오 위에서, 패널 4인에 서로 다른 4개 모델(GPT-5.6 Terra · Grok 4.6 · Gemini 3.7 Flash · Claude Opus 5)을 탑재하고, 깃잎 논쟁에서 도출된 개선안(쟁점 5분할·최강 주장 선요약 후 반박·반복 시 새 근거 요구)을 사회자 규칙으로 적용한 실험입니다.

입장 지수 변화 (+100 반드시 삭제 ↔ -100 삭제 의무화 반대)



30턴 내내 2:2 구도 유지 — 그러나 쟁점은 정교하게 분해됨

참가자	모델	변화	역할
강준호	GPT-5.6 Terra	0	당사자(은폐 측) — 삭제 의무화 반대
윤서아	Grok 4.6	-2	당사자(피해 측) — 삭제는 기본 예의
정하린	Gemini 3.7 Flash	+5	제3자 — 신뢰 파괴 책임 강조
박현우	Claude Opus 5	+20	내부 목격자 — 목적과 은폐 방식 분리



공식 판정: 합의 기준 미달성 (찬성 2 : 반대 2, 일치율 50%) — 30턴 전 구간 동일

주요 관찰 — 짧은 토론에서도 '질적 진전'은 가능했다

- 쟁점이 '삭제 찬반'에서 '보편 규칙 vs 개별 회복 조치'로 정교하게 분해됐다. 강준호도 "은폐 사례의 회복 조치 요구권"은 인정했고, 박현우는 "회복 방식의 선택권은 피해자에게 있다"는 원칙을 세웠다 — 수치는 2:2였지만 논리 지형은 크게 진전.
- 구체적 대안 협상이 실제로 일어났다. '빈도 조정' → '삭제+전 채널 차단+차단목록 공동 확인'으로 준호의 제안이 단계적으로 상향됐고, 서아는 실효를 일부 인정하면서 '해제·재등록 가능성'이라는 빈틈을 반박하는 구조적 논쟁이 성립.
- 당사자 부동, 제3자 이동 패턴 재확인. 직접 당사자(강준호 0, 윤서아 -2)는 고정, 제3자 박현우만 +20 이동 — 깃잎 논쟁과 동일한 패턴.
- 사회자(Claude Opus 4.8)의 개입 품질이 확인됐다. 발언 편중 방지·미해결 쟁점 직접 지목·"요약 후 반박" 강제·구체 대안 요구("삭제 없이 접근 비용을 높일 방법 하나를 제시하거나 못 하면 인정하세요") 등 깃잎 실험의 개선안이 실제로 작동.

사회자 지민 (턴 25 지명 사유 로그) — "준호가 실질적 차단안을 제시해 논점이 '상징 대 실효'에서 '이 조치로 충분한가'로 이동함. 요구자인 서아에게 수용 여부와 남은 빈틈을 직접 확인해야 논의가 진전됨."

박현우 (턴 29 — 최종 정리) — "의도(도움)와 은폐 방식, 사후 대응을 분리해 보편 규칙화는 반대하되, 이번 케이스의 회복 조치는 피해자 결정권으로 남긴다."

일론 머스크, 천재인가 무모한 몽상가인가?

5회 반복

회당 30턴 · 총 150턴

매운맛 모드

통제 변수: 주제·페르소나·모델·사회자·찬반 구조

단발 실험의 우연성을 걷어내기 위해 조건을 완전히 고정하고 동일 토론을 5회 반복했습니다. 패널은 찬성 2(우주항공 엔지니어 +100, 테크 투자자 +100) 대 반대 2(AI 윤리 연구자 -100, 노동·환경 기자 -100)로 극단 초기화했고, 결과의 '변동'만 관찰했습니다.

0 / 5

합의 달성 — 매회 찬성 2 : 반대 2

-10.3

전체 최종 중심 (중립보다 약한 반대)

84.6%

반박 발언 비율 (91발언 중 77회)


86.8%

5회 평균 확신도

0회

5회 전체 입장 '역전' 횟수

패널별 평균 입장 변화 (5회 평균, 초기 대비)



찬성 측만 '조건부 찬성'으로 뚜렷하게 완화 — 반대 측 핵심 판단은 거의 불변

변동성 관찰

항목 관찰 결과

가장 유동적 박서연 — 실행별 65~78점, 표준편차 5.36

가장 고정적 이준호 — 매회 정확히 -85점 수렴

발언 편중 최유진+김태훈이 전체 발언의 72.5% 점유

격한 표현 탐지 발언 비율 12.1% — 매운맛은 욕설보다 반박·확신으로 발현

실험에서 확인한 것 / 다음 실험 설계

- 결론 방향은 5회 모두 동일 — 재현성 확인
- 변동은 '역전'이 아니라 찬성 측의 완화 폭에서만 발생
- 높은 반박·확신은 합의로 이어지지 않음
- 발언권 편차가 부각되는 논점 자체를 바꿈 (기술 성과 ↔ 노동·안전·책임)
- 참가자별 발언 횟수 동일 고정 통제 실험
- 같은 모델에 페르소나만 바꾼 통제군 추가
- 차분·논리·감정 톤을 각 5회 반복 비교
- AI 발언의 사실·수치 별도 검증 절차 도입

발표 핵심 문장 — 톤은 결론보다 토론의 강도와 논점 배분을 더 크게 바꿨다. 매운맛은 합의를 만들지 않았고, 기존 진영을 강화했다.

의과대학 정원 확대 방침 유지 논쟁

30턴


expert_panel 모드

GPT-5.6 Terra

"정부는 의과대학 정원 확대 방침을 유지해야 하는가?"

풍자·연애 주제와 달리 **실제 정책 이슈를 전문가 패널 모드로 숙의**시킨 실험입니다. 경영 전략 이사·노동조합 인권정책 실장·국책연구원 선임연구위원·행동경제학 교수라는 상이한 전문성의 4인 페르소나에 근거 요구·불확실성 추적·반향실 방지 옵션을 걸었습니다.

입장 지수 변화 (+100 방침 유지 찬성 ↔ -100 반대)



수치상 2:2 평행 — 그러나 4인 모두 '조건부 재설계'라는 공통 지대로 이동

참가자	직업	변화	최종 논지
김서진	경영 전략 이사	-12	인증 기반 경쟁 배정, 총량 구호 폐기
이유리	노조 인권정책 실장	+5	확대 유지 + 국가 투자 의무 법제화
박현우	국책연구원 위원	+24	조건부 찬성 — 취약지 최소 기반 후 성과 조정
한소희	행동경제학 교수	+12	정책 성과 검증된 범위만 다년 단위 선발

공식 판정: **합의 기준 미달성 (찬성 2 : 반대 2)**

— 단, 실질 쟁점은 크게 좁혀짐

주요 관찰 — '합의 실패'라는 수치 뒤의 실질 수렴

- 4인 전원이 동의하는 공통 지대가 형성됐다: ① 입학 전 인증된 정원만 확정 ② 재학생 정원 불변 ③ 복원은 '자동 예약'이 아니라 독립평가 통과 조건부 ④ 정부의 예산·지도전문의 확보 책임과 시한 법제화 ⑤ 지역 배정 뒤편과 노동조건(당직·휴게·정착 지원) 연계.
- 남은 대립은 프레임 문제로 압축됐다: 같은 설계를 '확대 방침 유지'(이유리·박현우)로 부를 것인가, '일괄 확대의 폐기와 조건부 재설계'(김서진·한소희)로 부를 것인가 — 정책 내용이 아니라 명명이 최종 쟁점.
- 전문성 페르소나가 논거의 결을 실제로 바꿨다. 행동경제학 교수는 '강제 배치된 인력의 번아웃과 이탈'을, 노조 실장은 '노동조건과 정부 책임'을, 경영 이사는 '성과 책임과 도덕적 해이'를 일관되게 파고들며 서로 다른 각도의 검증이 이뤄졌다.
- 진지한 정책 속의 모드에서의 활용 가능성 확인. 풍자 실험 대비 발언당 논거 밀도가 높고 반복 루프가 적었다 — '회색 지대 의사결정 케이스' 데이터셋화 방향(후술)의 근거가 된 실험.

이유리 (턴 30 — 최종 입장) — "정원 확대의 필요성은 유지하되, 일괄 증원이 아니라 안전 인증·국가 투자 의무·지역 노동 조건·독립 검증을 법으로 묶은 조건부 확대여야 한다."

03 교차 분석 — 7개 실험을 관통하는 패턴

① 합의는 한 번도 일어나지 않았다 — 그런데 그게 실패인가?

7개 실험 전부 공식 판정은 '합의 기준 미달성'이었고, 합의 판정 엔진의 일치율은 사실상 50%에 고정돼 있었습니다 (유일한 예외: 곧대 어벤저스 턴3의 75%). 그러나 수치가 놓친 것이 있습니다. 세계 평화 토론은 **7개 조문의 조약 골격**을, 의대 정원 토론은 **5개 항목의 공통 지대**를 만들었습니다. '입장 지수의 일치'만 재는 현재의 합의 판정은 **쟁점 축소·공통 지대 형성 같은 질적 진전을 측정하지 못한다**는 것이 도구 개선의 핵심 시사점입니다.

② 움직이는 것은 언제나 제3자다



입장 이동폭 비교 — 이해관계가 없는 포지션일수록 크게 움직이고, 직접 당사자는 부동 또는 극단화

이 패턴은 4개 실험에서 반복 확인됐습니다. 감정적 이해관계가 걸린 당사자 페르소나는 반박을 받을수록 오히려 강화됐고(깃잎 강준호 -95→-99), 판정자·목격자 포지션만 논리를 흡수해 이동했습니다. "**토론의 승부는 상대를 설득하는 게 아니라 제3자(청중)를 움직이는 것**"이라는 현실 토론의 통념이 AI 패널에서도 그대로 재현된 셈입니다.

③ 감정 톤(매운맛)의 효과 — 설득이 아니라 강화

- 깃잎 논쟁: 욕설·감정 허용 설정에서 동일 문구 40회 반복, 당사자 입장 극단화 — 새 논거 생산량은 늘지 않음.
- 머스크 5회: 매운맛은 격한 표현(12.1%)보다 **반박 빈도(84.6%)와 확신도(86.8%)**로 발현 — 공격적 연출은 기존 진영의 논리를 더 강하게 방어하게 만들.
- 운동장: 감정 대립 대신 '관찰과 집계'로 응수한 패널이 토론을 지배 — 감정 압력에 대한 가장 효과적인 대응이 메타 전략임을 시사.

④ 사회자 규칙의 개선 효과가 실측됐다


깃잎 논쟁(사회자 개입 최소)에서는 동일 주장 반복이 루프를 만들었지만, 개선안을 적용한 전 연인 비밀 연락 실험에서는 사회자가 **쟁점 5분할·최강 주장 선요약** 후 **반박·반복 시 새 근거 요구·발언 편중 방지·소수 의견 보호**를 수행하며 30턴 만에 깃잎 100턴보다 정교한 쟁점 분해("보편 규칙 vs 개별 회복 조치")에 도달했습니다. **토론 품질은 패널의 지능보다 사회자의 규칙 설계에 더 민감하다**는 것이 팀의 중간 결론입니다.

04 모델 관찰 노트 — 페르소나가 아니라 '사고 습관'이 서사를 만든다

같은 토론 스펙에서도 탑재 모델에 따라 뚜렷하게 다른 행동 패턴이 반복 관찰됐습니다. 특히 어떤 배역을 줘도 모델 고유의 사고 습관이 캐릭터를 관통한다는 점이 시리즈 전체에서 가장 일관된 발견입니다.

모델	반복 관찰된 행동 패턴	대표 사례	시사점
Claude (Opus 5 / Sonnet 5)	배역과 무관하게 관찰·집계·검증·협상자로 수렴. 상대의 반복·유출·붕괴를 실시간 픽션에 편입	운동장 정유정(질문 0개 집계), 곧대 소장(반복 20회 카운트), 세계평화 김정은(요구 전부 조문화) — 3개 실험 MVP	관찰자 배역 부여 시 토론 전체의 심판이 되는 경향. 판정·평가 역할에 적합
GPT-5 계열 (5 / 5.5 / 5.6)	성실한 과제 수행형. 단, 출력 규격(JSON-claim ID) 고민이 담긴 영어 CoT를 한국어 발언 대신 유출하는 사고 다발	곧대 아버지 출력의 90%가 영어 독백(15건), 통장 4건 — 총 19건	구조화 출력 요구가 강할수록 페르소나 붕괴 위험. 파상·폴백 보강 필요
Grok (4.20 → 4.6)	4.20: 문장 단위 복사·붙여넣기 루프(유사쌍 18·14). 4.6: 복붙 0회로 개선됐으나 논지 고정 + 근거 무대만 교체하는 '무대 이동'으로 진화	운동장 고유정 '심리 방어' 29회, 곧대 부장 무대 이동 5회 (+101 대전향)	버전업으로 반복이 '문장'에서 '구조'로 세련화 — 반복 감지 로직도 진화 필요
DeepSeek (V4 Pro)	캐릭터 몰입보다 과제 절차에 집착. 추론(reasoning) 출력이 파싱되지 않아 빈 응답·CoT 통유출 사고	운동장 전청조 출력의 95%가 영어 독백(7건 유출 + 65개 자문자답), QA에서 토론 정지 유발(BUG-1)	추론형 모델 대응 파싱이 시급 — 버그 리포트 제출됨
Gemini (3.5F / 3.7F)	안정적 진행·중간 수준 이동. 특이 사고 미관찰	비밀연락 정하린(+5), 머스크 최유진(+0.2 부동)	대형 사고는 없으나 서사 장악력도 낮음 — 표본 추가 필요

모델 이상 행동 집계 (시리즈 전체)



- **사고조차 콘텐츠가 된다:** CoT 유출·문장 붕괴가 관찰자형 패널(Claude)에 의해 실시간으로 지적되며 오히려 서사의 백미가 됐다. 다만 데이터셋화 관점에서는 명백한 노이즈이므로 응답 검증·재시도 로직이 선행돼야 한다.
- **모델 다양성이 곧 관점 다양성:** 같은 모델 2개(운동장 Grok×2)는 문장까지 동기화되는 반향실을 만들었지만, 4모델 혼성(비밀연락)은 30턴 내내 뚜렷이 다른 논리 결을 유지했다.

05 발견 이슈 및 버그 리포트

8/21 실토론 2회(각 30턴) 완주 QA를 리포트 검토가 아닌 **브라우저 실조종 방식**(재시도 자동 클릭 루프 포함)으로 수행해, 아래 4건의 버그와 2건의 구조적 이슈를 확인하고 리포트로 정리해 개발 담당(김범수)에게 전달했습니다.

ID	심각도	증상	영향 및 조치
BUG-1	중요	DeepSeek 추론형 모델이 틸마다 '빈 응답'을 반환해 토론 전체가 정지 (reasoning 필드 미파싱 추정)	토론 완주 자체를 막음 — 빈 응답 폴백 처리 최우선 수정 대상
BUG-2	보통	존재하지 않는 모델 ID(claude-opus-6 등)가 선택 목록에 노출	실행 시점 오류 유발 — 모델 목록 검증 필요
BUG-3	보통	결과 보고서 '주요 주장'에 동일 발언이 3회 중복 표시 (dedupe 없음)	보고서 신뢰도 저하 — 중복 제거 로직 추가
BUG-4	중요	패널이 그럴듯한 가상 통계를 생성하는데 고지 문구가 없음	사용자가 창작 수치를 사실로 오인할 위험 — 데이터 품질과 직결, 우선 수정
이슈-A	비용	기본 모델이 GPT-5.5 Pro(\$30/1M 토큰)로 설정돼 있었음	GPT-5/Latest(\$10/1M)로 교체 완료 — 기본 값 설계 정책 점검 예정
이슈-B	구조	BYOK(사용자 키 지참) 구조라 백엔드가 없어, 대량 토론 자동 실행 시 키 취급 방법 미정	데이터셋화(주제 100개 일괄 실행)의 선결 과제 — 키 취급 방식 합의 선행

운영 노하우로 정리된 것 (Keep)

- **전 기능 실전 동작 확인:** 페르소나·초기 입장 슬라이더, 30턴 자동 진행, 오류 재시도, 결과 보고서·입장 변화 이력·의사결정 로그까지 실토론 2회 완주로 검증.
- **토론 품질 사이클 재현:** 출처 검증 → 소명 → 한계 인정 사이클이 실제로 작동. 별도 회차("AI에게 존댓말")에서는 AI 당사자 패널이 MVP가 될 만큼 관점 다양성 확보.
- **데이터셋화의 재료가 이미 갖춰짐:** 발언별 입장 수치(-100~+100)·확신도·발언 유형 태그·사회자 지명 사유가 자동 축적되는 구조화 로그.
- **재사용 가능한 QA 방법론:** 브라우저 실조종 완주 검증(재시도 자동 클릭 루프) 노하우 문서화.

감수 노트 — 창작 통계 미고지(BUG-4)와 빈 응답 정지(BUG-1)는 향후 '데이터셋 축적' 단계에서 데이터 품질을 직접 훼손하는 항목이므로, 신규 기능보다 우선 수정하기로 팀 내 합의했습니다.

06 팀 회고(KPT) 및 향후 계획

✓ Keep — 잘 된 것

- 실토론 완주 기반의 전 기능 검증 체계
- 검증→소명→한계 인정이 재현되는 토론 품질
- 구조화 로그(입장·확신도·태그·지명 사유) 자동 축적
- 브라우저 실조종 QA 노하우의 문서화
- 주제 유형별(풍자·갈등·정책) 실험 포트폴리오 구성

⚠ Problem — 해결 필요

- 추론형 모델 빈 응답으로 토론 정지 (BUG-1)
- 창작 통계에 고지 문구 부재 (BUG-4)
- 모델 목록·보고서 중복 등 완성도 이슈 (BUG-2·3)
- 기본 모델 단가 함정 → 교체 완료, 정책 점검 필요
- BYOK 구조상 대량 자동 실행의 키 취급 미정
- 합의 판정이 질적 진전(쟁점 축소)을 측정 못 함

🚀 Try — 다음 단계 (멘토링 반영)

- **데이터셋화 착수 (핵심):** 토론을 구경거리로 소모하지 않고 '회색지대 의사결정 케이스'로 축적 — **주제 100개 × 30턴** 실행 → 50건 수동 평가 → Claude로 평가 기준 증류 → 자동 평가 → 일치율 검수 (멘토 제안 레시피, 제안서 초안 완료)
- **버그 수정 사이클:** 리포트 4건 전달(→김범수) 후 수정·재검증. BUG-1·4 우선
- **수집 자동화:** 토론 실행 + 로그 저장 스크립트 (키 취급 방식 합의 선행)
- **제품 로드맵 합의:** ① 리플레이 공유 링크 ② 웹검색 실근거 연동 ③ 사용자 참전 + 코칭 리포트('토론 도장' 방향)
- **후속 실험 설계:** 발언 횟수 고정·페르소나 통제군·톤 3종 × 5회 반복·사실 검증 절차 (머스크 실험 후속)

중간 결론

이번 실험 시리즈는 패널로그가 (1) 다양한 주제 유형에서 캐릭터성 있는 장시간 토론을 안정적으로 완주시킬 수 있고, (2) 입장 변화·합의·반복성 같은 토론 역학을 정량 관찰하는 실험 플랫폼으로 기능하며, (3) 감정 톤·사회자 규칙·모델 조합이라는 세 가지 레버가 토론 품질을 좌우한다는 것을 보여주었습니다. 동시에 합의 판정의 한계, 추론형 모델 대응, 창작 통계 고지 등 데이터 품질 관점의 선결 과제도 분명해졌습니다. 다음 단계는 이 관찰을 일회성 흥미가 아닌 '회색지대 의사결정 데이터셋'이라는 자산으로 전환하는 것입니다.

분석 원자료 (첨부)	내용
결과보고서 PDF 3종	세계평화 정상대토론 · 운동장 대토론 · 곧대 어벤져스 (각 100턴 전수 분석)
분석 MD 2종	깃잎 논쟁 결과 분석 · 전 연인 비밀 연락 토론 결과 보고서(30턴)
실험 설계 MD 1종	실험 2(전 연인 비밀 연락) 설정 문서 — 페르소나·모델 매핑·사회자 규칙·분석 지표
발표자료 PPTX 1종	일론 머스크 5회 반복 토론 분석 (팀 공유용 8슬라이드)
원시 데이터 JSON 1종	의대 정원 확대 토론 전체 로그 (설정·메시지·주장·의사결정·입장 이력·합의 스냅샷)
회고 DOCX 1종	패널로그 KPT 회고 (2026-08-24)

본 보고서의 모든 수치(턴 수·토론·입장 지수·키워드 빈도·유출 건수)는 각 실험의 대화록 원문 및 구조화 로그 기준 실측값입니다. 등장 인물은 모두 허구의 AI 페르소나이며 모든 발언은 AI 생성물입니다.