

AIFFEL 아이펠톤 · Panelogue 프로젝트

팀 인간시대의 끝이 도래했다

여러 AI를 토론시키면 합의에 도달할까

이질적 LLM 멀티에이전트 토론 8주제·16세션 760턴 탐색적 사례 연구

김범수 · 박대건 · 이종현 · 김동건

2026. 09. 09

8

토론 주제

16

세션

760

전체 턴



그 디스크를 현실로 옮기면 4단계입니다

능력을 심는 방법은 층이 나뉘어 있고, 층마다 심어지는 것이 다릅니다

1

프롬프트 페르소나

말투와 역할만 지정합니다. 솔직히 연기에요. 껌데기입니다.

현재 저희 시스템

2

RAG

참고서를 옆에 놔둔 것. 지식은 정확해지는데 할 수 있는 일은 안 늘어납니다.

3

스킬 · 툴

절차적 능력. 실제로 새로 할 수 있는 게 생깁니다. 지금 제일 실용적인 층.

4

파인튜닝 · LoRA

가중치를 직접 건드립니다. LoRA 어댑터는 실제로 핫스왑됩니다.

디스크에 가장 가까움

네 층 어디를 올려도 네오는 계속 네오입니다 — 인격과 능력은 별개의 축입니다

정답이 없는 주제라면?

멀티에이전트 토론 연구의 사각지대

정답이 있는 과제

- 수학 · 사실 확인 · 추론
- 여러 모델이 서로 비판 → 오류 감소
- 효과가 보고된 영역

정답이 없는 주제

- 정책 · 인물 평가 · 관계 갈등
- 같은 자료라도 가치 우선순위가 다르면 결론이 갈림
- 합의가 목표가 맞는가?

그래서 질문을 바꿨습니다

“합의했는가” 가 아니라 — “합의하지 못했다면 무엇이 남았는가”

저희가 돌린 8개 주제

자료

무거운 것부터 사소한 것까지 — 공통점은 전부 정답이 없다는 것

ID	토론 주제	세션	턴	공식 합의
E1	세계 평화 정상 대토론	1	100	미달성
E2	운동장 대토론 (사람을 속이는 법)	1	100	미달성
E3	대한민국 폰대 어벤져스	1	100	미달성
E4	깟잎 논쟁	1	100	미달성
E5	전 연인 비밀 연락	1	30	2 : 2 분할
E6	일론 머스크 평가	5	150	0 / 5
E7	의대 정원 확대	1	30	2 : 2 분할
E8	VAR · AI 심판 개입	5	150	0 / 5
합계	8개 주제	16	760	0 / 16

Panelogue — 사회자 1 + 패널 4

시스템

패널마다 모델도, 성격도, 출발 입장도 다릅니다

6

모델 제공사 (9종)

5


에이전트 / 세션

± 100

입장 지수 범위

760

전체 시스템 턴



패널마다 다르게 부여한 것

- 서로 다른 제공사의 LLM
- 직업 역할 · 가치관 · 말투
- 초기 입장 (-100 ~ +100)

발언마다 저장되는 구조화 필드

- 입장값 · 확신도 · 발언 유형
- 어떤 발언에 영향받았는지 (메시지 ID)

← 이 필드가 뒤에서 핵심이 됩니다

모델 구성은 원자료가 있는 5개 주제 기준 — 제공사 6곳 · 모델 9종 · 세션과 주제에 따라 조합이 달라 모델 자체의 효과는 분리되지 않습니다

실제로는 이렇게 굴러갑니다

대한민국 쏘대 어벤져스 — “요즘 젊은이들은 왜 우리 말을 안 듣는가”

아파트 관리 소장 · 2턴

“젊은 입주민들이 말을 안 듣는 게 아니라 근거 없는 요구를 안 듣는 겁니다.
분리배출 시간을 게시판에 규정 조항까지 붙여놓으면
20대 세대가 오히려 제일 잘 지킵니다.”

회사 부장 · 4턴

“소장님, 규정 붙여놓는다고 회사가 돌아갑니까.
나는 과장 달 때까지 주말에도 나와 일했는데
요즘은 워라밸이라며 6시면 컴퓨터부터 꺼버려요.”

로그에 남은 것

바로 이 순간, 회사 부장의 입장값이 -25 → +35 로 기록됩니다

합의는 16번 모두 실패했습니다

결과 1

그러나 실패와 무산출은 같은 말이 아니었다

0 / 16

공식 합의 달성 세션

부호 역전 0건

반박 84.6% / 85.4%

양보 2건 / 1건

머스크 / VAR 반복 10회 기준

그런데 사후 코딩에서 나온 것

세계 평화 토론

7개 조문의 조약 골격 — 발동 기준, 자동 발효, 대칭 정지

의대 정원 토론

인증 · 재정 · 지역배분 · 노동조건을 담은 조건부 정책안

VAR 토론


판정 로그 공개 · 개입 시간 제한 · 이의제기 절차

→ 마지막 부호 하나로 토론을 평가하면, 이 산출물이 전부 지워집니다.

평균 0의 함정

결과 2

중립처럼 보이는 숫자가 사실은 양극단의 상쇄



부호 있는 평균 하나만 보면 정반대로 읽게 됩니다.

-1.45

집단 평균 (부호 있음)

95.55

평균 절대 입장 (5회 평균)

2:2

찬반 분할 (5회 모두)

누가 무슨 말을 했을 때 누가 움직였나

방법

로그에서 인과 사슬을 복원하는 법

stanceHistory

입장이 바뀐 시점과
변경 사유

+

influencedBy
MessageIds

그 변화를 일으킨
메시지 ID

+

messages

해당 발언의
원문 텍스트

5개 주제 · 입장 변화 185건 · 트리거 구절 전건 연결

= “어떤 구절이 누구의 입장을 몇 점 움직였는가” 를 전건 복원

185건

복원된 입장 변화

5주제

12개 실행

9범주


트리거 자동 분류

총 13회 실행 중 VAR 3회차는 입장 변화가 0건이어서, 사건이 기록된 실행은 12개입니다

턴별 입장 변화 — 계단 그래프

시각화

수직으로 꺾이는 지점이 곧 ‘반응한 순간’, 원형은 입장 변화 사건



반응을 부른 구절을 모아 분류했습니다


시각화

185건의 트리거 구절 자동 1차 코딩 결과

① 어떤 범주의 구절이 많았나



② 페르소나를 건드리면 굳는가, 누그러지는가



대표 트리거 구절 — 반응을 부른 문장을 전부 모아 분류했습니다

“규정 조항까지 붙여놓으면
20대 세대가 오히려 제일 잘 지킵니다”

수치·사실·근거 · 117건 · 평균 5.9점

“1단 부스터 착륙시키고 다시 날려서
발사 시장 판을 갈아엎었어”


성과·실행 가능성 · 17건 · 평균 10.0점

“8년 넘게 반복해서 못 지킨 건
어떻게 설명할 거야?”

사회자 질문·선택 압박 · 7건 · 평균 11.0점

그런데 — 결론이 설계의 산물이었습니다

초기값을 어디에 뒀느냐가 변화 방향을 미리 결정한다



21건

직전 입장이 ± 100 이던 사건 — 강화 = 정확히 0건

입장 지수는 ± 100 이 한계입니다.
경계에서 출발하면 더 강해지는 것이
산술적으로 불가능합니다.

통계 결과가 아니라 척도 정의에서
따라 나오는 귀결입니다.

“토론하면 입장이 누그러진다”는 관찰이, 사실은 초기값 설계가 만든 결과일 수 있습니다

분명히 해둘 한계

한계

저희는 이 연구를 ‘가설 생성용 사례 연구’로 규정합니다

1

완전요인 실험이 아닙니다

주제 · 모델 · 페르소나 · 초기값 · 사회자가 함께 달라져 단일 원인의 효과를 분리할 수 없습니다

2

185건 전부 자동 코딩입니다

규칙 기반 1차 분류이며 사람 검토와 코더 간 일치도(κ)를 거치지 않았습니다

3

경계 효과가 전부는 아닙니다

여지를 맞춰 총화해도 격차가 남고, 그 잔차는 사회자·주제·모델과 교란되어 분리 불가능합니다

결론

01

**마지막 부호 하나로
평가하지 말 것**

입장 궤적 · 극단성 · 부호 분할 ·
절차적 산출물 · 소수 의견 보존을 함께

02

**초기값을
통제 변수로 명시할 것**

4×4 라틴 스퀘어 교차 ·
초기 입장 ±60 대칭 배정

네오는 디스크를 꽂아도 네오였습니다.

능력은 심을 수 있어도, 그 능력이 무엇을 바꿨는지는 따로 재야 합니다.

감사합니다.

팀 인간시대의 끝이 도래했다 · 김범수 · 박대건 · 이종현 · 김동건

8주 동안 무엇을 했나

발표 중에는 넘기지 말고, 물어보면 띄우세요

95

문서 산출물

294

저장소 전체 파일

185

코딩한 입장 변화

760

실행한 토론 턴

단계별로 한 일

실험	8주제 · 16세션 · 760턴 실행	결과보고서 5
중간 점검	버그리포트 · KPT 회고 · 중간보고서	문서 3
분석	인과 사슬 복원 185건 전건 코딩	패키지 3종
논문	v1 원본에서 v5까지 5차 개정	docx 6 · pdf 4
발표	슬라이드 15장 · 대본 3종	pptx 3 · md 4
검증	슬라이드 62 + 대본 49 항목 자동 대조	스크립트 2

종류별 산출물

PDF	15	DOCX	9
PPTX	5	MD	63
CSV	37	JSON	30
PNG	24	Python	69