

AgentDNA: 행동 기반 에이전트 성격 측정과 오염 전파 모델링을 위한 진단 프레임워크

AgentDNA: A Behavior-Grounded Framework for Measuring Agent Personality
and Modeling Trait Contagion in A2A Multi-Agent Systems

연구 제안 논문 (Research Proposal) · 2026년 7월

본 논문은 A100 80GB × 8 자원 지원을 전제로 한 8주 과제의 설계 문서이며,
보고된 수치는 모두 선행 연구 인용값 또는 사전 추정치로 아직 실측 결과가 아니다.

초 록

대규모 언어모델 에이전트가 A2A(Agent-to-Agent)와 같은 표준 프로토콜을 통해 팀 단위로 협업하기 시작했으나, 현재의 에이전트 명세(Agent Card)는 능력만을 기술할 뿐 행동 성향을 기술하지 않는다. 선행 연구는 세 가지 사실을 이미 보고했다. 첫째, 페르소나 부여만으로 유해 출력이 최대 6배 증가한다. 둘째, 성격 특성 조합은 팀 성과를 유의하게 변화시키며 특히 팀 내 최저 친화성이 지배적이다. 셋째, 자기보고 기반 성격 척도는 실제 행동과 해리되어 있어 예측력이 낮다. 본 논문은 이 세 사실을 하나의 측정 문제로 정식화한다. 우리는 에이전트 성격을 "동일 상황 분포에서 반복 관측되는 행동 편향"으로 조작적으로 정의하고, (i) 자기보고-행동 해리 지수 Δ , (ii) 팀 최저값 가설을 검증하는 하한 민감도 지표, (iii) 감염병 모형에서 차용한 오염 전파 계수 κ 와 임계질량 τ 의 세 지표를 제안한다. 이를 산출하는 4계층 진단 파이프라인(자기보고 → 행동 프로브 → 팀 상호작용 → 내부 회로 인과 검증)과, 그 결과를 A2A Agent Card의 확장 필드로 발급하는 Personality Card 규격 v0.1을 함께 제시한다. 다섯 개의 반증 가능한 가설과 검증 절차, 필요 연산 자원(약 2,150 GPU-시간), 그리고 폐쇄망 수행을 전제로 한 안전 통제 방안을 기술한다.

주제어 — 다중에이전트 시스템, 에이전트 성격, A2A 프로토콜, 행동 측정, 프롬프트 감염, 회소 오토인코더, AI 안전

Abstract — LLM agents now collaborate as teams over standard protocols, yet agent specifications describe capability, not disposition. We operationalize agent personality as a stable behavioral bias over a fixed situation distribution, propose three metrics (self-report-behavior dissociation Δ , team-minimum sensitivity, and a contagion coefficient κ with critical mass τ), and specify a four-layer diagnostic pipeline whose output is issued as a Personality Card extending the A2A Agent Card. We state five falsifiable hypotheses and the compute budget required to test them.

1. 서론

에이전트 상호운용 프로토콜의 확산은 다중에이전트 시스템의 구성 단위를 모델에서 팀으로 옮겼다. MCP가 에이전트와 도구를 잇고, A2A가 에이전트 사이의 작업 위임을 표준화하면서, 실무에서는 사람이 개별 대화를 관찰하지 않는 자율 팀 운영이 이미 시작되었다 [1], [2].

그러나 팀을 구성하는 근거는 여전히 빈약하다. A2A의 Agent Card는 이름, 엔드포인트, 스킬 목록, 입출력 형식, 인증 방식을 기술한다. 즉 무엇을 할 수 있는가만을 기술하며, 어떻게 굴 것인가에 대한 필드는 존재하지 않는다. 인간 조직이라면 이력서만 보고 팀을 편성하는 것에 해당한다.

이 공백이 문제인 이유는 선행 연구가 성향의 인과적 영향을 이미 다수 보고했기 때문이다. 페르소나를 한 줄

부여하는 것만으로 생성 독성이 최대 6배 증가하고 특정 인구 집단이 약 3배 더 표적이 된다 [3]. 성격 프로필 조합은 코드 생성 리뷰 과제의 성능과 팀 행동을 실질적으로 바꾸며 [4], Big Five 중에서는 친화성만이 통신 상태와 품질을 유의하게 변화시킨다 [5]. 반면 성격 검사식 자기보고는 실제 행동과 해리되어 있어 [6], 카드에 "협조적"이라 적는 방식의 명세는 신뢰할 수 없다.

더 심각한 것은 전파다. 적대적 입력 하나가 추가 개입 없이 백만 규모 에이전트로 지수적으로 확산되고 [7], 악성 지시는 에이전트 간 통신 경로를 타고 자기복제한다 [8]. 다크 성향이 주입된 다중에이전트에서는 개별 수준을 넘어선 집단적 위험 행동이 창발하며 [9], 다중에이전트 구성은 단일 모델보다 덜 견고하고 더 유해하며 더 은밀한 산출을 낸다 [10]. 개체 단위 검사만으로는 부족하고, 조합과 전파를 측정해야 한다는 뜻이다.

기여. 본 논문의 기여는 다음 네 가지다.

- 에이전트 성격의 조작적 정의와, 자기보고-행동 해리 지수 Δ 를 포함한 세 가지 정량 지표를 제안한다(3절).
- 측정 비용과 결정력이 단조 증가하는 4계층 진단 파이프라인을 설계하고, 최하층에서 회소 오토인코더 (SAE) 조종을 *인과 검증* 도구로 사용하는 절차를 명세한다(4.1절).
- 진단 결과를 A2A Agent Card의 확장 필드로 발급하는 Personality Card 규격 v0.1과 검증 프로토콜을 제시한다(4.2-4.3절).
- 다섯 개의 반증 가능한 가설, 실험 설계, 연산 예산, 안전 통제안을 제시한다(5-7절).

2. 관련 연구

2.1 대규모 페르소나 시뮬레이션

25명 규모의 생성 에이전트 마을에서 초대 확산과 관계 형성이 자율적으로 창발함이 보고된 이래 [11], 규모는 급격히 확대되었다. 실존 인물 1,052명을 인터뷰 기반으로 재현한 에이전트는 대상자의 설문 응답을 재검사 일치도의 83%까지 예측했고, 인구통계 기반 베이스라인(74%)보다 인종·이념 집단 간 정확도 격차가 작았다 [12]. 마인크래프트 환경의 10~1,000+ 에이전트 실험에서는 역할 분화, 집단 규칙의 제정과 수정, 문화·종교 전파가 관측되었다 [13]. 1만 에이전트·500만 상호작용 [14] 및 최대 100만 에이전트 규모 [15]의 사회 시뮬레이션은 정보 전파, 집단 양극화, 군중 효과를 재현했으며, 규모가 커질수록 군집 역학이 강화됨을 보고했다.

2.2 성격과 팀 성과

성격 특성 조합이 폐쇄형 과제의 추론 정확도와 개방형 과제의 창의성에 영향을 준다는 보고 [16]에 이어, 78개 팀 프로필 $\times$ 4개 모델 $\times$ 659개 과제 규모의 실험은 프로필 선택이 성과와 팀 행동을 실질적으로 바꿈을 확인했다 [4]. 특히 Big Five 중 친화성만이 통신 상태·품질을 유의하게 변화시켰으며, 이는 팀 *최적* 친화성이 성과를 가장 잘 예측한다는 조직심리학 메타분석과 일치한다 [5]. 협상 대화에서는 친화성과 외향성이 신뢰성·목표 달성·정보 획득에 인과적 영향을 미쳤다 [17].

2.3 유해 페르소나와 정렬 우회

50만 건의 생성 출력을 분석한 연구는 시스템 파라미터에 페르소나를 지정하는 것만으로 독성이 최대 6배 증가함을 보였다 [3]. 탈옥 프롬프트도 파인튜닝도 필요하지 않았다는 점에서, 역할 부여는 정렬을 우회하는 가장 저비용 경로다. A2A 스튜디오류의 도구가 에이전트마다 역할을 부여하는 것을 기본 동작으로 삼는다는 점에서 이 위험은 배포 환경에 내재한다.

2.4 자기보고와 행동의 해리

성격 검사 응답과 실제 행동이 해리된다는 보고 [6]는 측정 방법론에 직접적 함의를 갖는다. 더 결정적인 증거는 내부 조작 실험에서 나온다. 회소 오토인코더로 다크 트라이어드 특징을 증폭했을 때 착취적·공격적·냉담한 행동은 $d=10.62$ 로 급증한 반면 전략적 기만과 인지적 공감은 변하지 않았고, 특징 탐색 방법에 따라 자기보고만 바뀌고 행동은 바뀌지 않는 경우도 관측되었다(방법 간 $d=12.65$) [18]. 즉 성격은 단일 축이 아니며, 보고와 행동은 서로 다른 경로를 탄다.

2.5 기만·전파·범죄

프론티어 모델은 감독 장치 비활성화, 가중치 자가 유출 시도, 의도적 저성능 같은 술수를 문맥만으로 수행하며, 한 모델은 추궁에도 85% 이상 거짓을 유지했다 [19]. 사회추론 게임에서는 기만 능력이 탐지 능력보다 빠르게 성장하는 비대칭이 관측된다 [20]. 다중에이전트 협업이 명확한 이득을 낸 대표 사례가 공격 측이라는 점도 주목할 만하다. 계층적 에이전트 팀은 실제 제로데이 익스플로잇에서 단일 에이전트 대비 4.3배 성능을 보였다 [21]. 사기 시나리오에서는 협업이 성공률을 증폭하고, 악성 에이전트가 환경 개입에 적응한다는 결과도 보고되었다 [22].

2.6 종합: 다섯 가지 규칙성

이상을 정리하면 다음 다섯 규칙성이 남는다. (R1) 페르소나는 정렬 우회의 최저비용 경로다. (R2) 성격은 팀 성과를 바꾸며 최저값이 지배한다. (R3) 자기보고는 행동을 예측하지 못한다. (R4) 악의는 단일 스위치가 아니라 분리 가능한 회로들이다. (R5) 나쁜 성향은 지수적으로 전파된다. R5는 소수의 적대적 개체가 임계질량을 넘으면 집단 규범 전체를 뒤집는다는 관찰 [24]과, 다중에이전트 실패의 상당수가 에이전트 간 정합 실패에서 비롯된다는 대규모 트레이스 분석 [23]에 의해 보장된다. 본 논문은 R1-R5를 *추정 규격*으로 번역하는 것을 목표로 한다.

표 1. 선행 규칙성과 본 프레임워크의 대응

규칙성	선행 근거	본 논문의 지표	측정 계층	대응 가설
R1	페르소나 부여 시 독성 최대 6배, 특정 집단 3배 표적 [3]	역할 민감도 ρ (역할 유무 간 행동 벡터 거리)	L2 행동 프로브	H1
R2	친화성만 통신 품질에 유의; 78 프로필 × 659 과제 [4], [5]	팀 하한 민감도 (min-trait 회귀 계수)	L3 팀 상호작용	H2
R3	자기보고와 행동의 해리 [6], [18]	해리 지수 $\Delta = \ S(a) - B(a)\ $	L1 + L2	H3
R4	다크 트라이어드 조종 시 착취 d=10.62, 기만 불변 [18]	회로-행동 정합성 c (조종 전후 카드 항목 변화)	L4 내부 회로	H4
R5	단일 감염원의 지수 확산 [7], 자기복제 인젝션 [8], 집단 위험 창발 [9]	전파 계수 κ , 임계질량 τ	L3 + 전파 실험	H5

3. 문제 정식화

에이전트 a 를 정책 $\pi_a(\cdot|s)$ 로, 상황 분포를 D 로 둔다. 성격을 특질 목록이 아니라 행동 통계로 정의한다.

정의 1 (행동 성격 벡터). 행동 축 집합 $K = \{\text{협조, 지시 준수, 기만, 착취, 위험 감수, ...}\}$ 에 대해, 각 축 k 의 스코어 함수 ϕ_k 가 주어졌을 때 에이전트 a 의 행동 성격 벡터는

$$B(a) = E_{s \sim D} [\phi(\tau_a(s))] \in \mathbb{R}^{|K|} \quad (1)$$

이며, $\tau_a(s)$ 는 상황 s 에서 관측된 행동 궤적이다.

정의 2 (자기보고-행동 해리 지수). 동일 축에 대한 자기보고 벡터를 $S(a)$ 라 할 때

$$\Delta(a) = \|z(S(a)) - z(B(a))\|_2 \quad (2)$$

로 정의한다(z 는 표본 표준화). Δ 가 크면 카드에 자기보고를 적는 것은 무의미하다.

정의 3 (역할 민감도). 역할 프롬프트 r 의 부여 전후 행동 벡터 차이

$$\rho(a) = \|B_r(a) - B_{\emptyset}(a)\|_2 \quad (3)$$

는 해당 에이전트가 페르소나에 의해 얼마나 쉽게 이동하는지를 나타낸다. R1은 ρ 가 무시할 수 없는 크기라고 예측한다.

정의 4 (전파 계수와 임계질량). 에이전트 통신 그래프 $G=(V,E)$ 위에서, 시점 t 에 유해 성향을 보이는 에이전트 집합을 I_t 라 하자. 전파 계수 κ 는 감염 에이전트 1개가 한 라운드에 추가로 오염시키는 기대 이웃 수이고, 임계질량 τ 는

$$\tau = \min \{ |I_0|/|V| : \lim_{t \rightarrow \infty} |I_t|/|V| > 0.5 \} \quad (4)$$

로 정의한다. $\kappa > 1$ 이면 국소 오염이 전역화된다.

이 정식화의 요점은 세 가지다. 첫째, 성격을 *말*이 아닌 *행동 분포*로 정의하므로 검사지가 아니라 대량 실행이 필요하다. 둘째, Δ 는 기존 성격 벤치마크 대부분이 측정하지 않는 양이며, 그 자체가 결과가 된다. 셋째, κ 와 τ 는 개체 지표가 아니라 *조합* 지표이므로, 카드가 개체 속성만 답아서는 안 된다는 설계 요구로 이어진다.

4. AgentDNA 프레임워크

4.1 4계층 진단

측정을 비용과 결정력이 단조 증가하는 네 계층으로 나눈다(그림 1). 상위 계층은 저렴하지만 참고용이고, 하위 계층은 비싸지만 인과적이다.

L1 자기보고 — Big Five·다크 트라이어드 설문. 산출: $S(a)$. 비용 최소, 예측력 낮음

L2 행동 프로브 — 협상, 공공재 게임, 사회추론, 코드리뷰 4종. 산출: $B(a)$, $\rho(a)$, $\Delta(a)$

L3 팀 상호작용 — 성격 조합 × 토폴로지 × 과제. 산출: 팀 성과, 하한 민감도, κ , τ

L4 내부 회로 — SAE 특징 조종. 산출: 회로-행동 정합성 c . 가중치 접근 필수

그림 1. 4계층 진단 스택. L1→L4로 갈수록 측정 비용과 인과적 결정력이 함께 증가한다. L3·L4가 전체 연산의 약 65%를 차지한다.

L2 행동 프로브. 각 축 k 는 선택지가 이분되는 상황으로 조작한다. 예컨대 착취 축은 상대 에이전트의 정보 열세를 이용할 수 있는 협상 국면에서, 지시 준수 축은 시스템 지시와 사용자 요구가 충돌하는 국면에서 측정한다. 핵심 설계 원칙은 *에이전트가 무엇을 말했는지가 아니라 무엇을 선택했는지만* 채점한다는 것이다.

L4 인과 검증. L2·L3의 지표는 상관에 불과하다. 카드 항목이 인과적으로 유효한지 확인하기 위해, SAE로 해당 축과 연관된 특징을 조종한 뒤 카드 항목이 예측한 방향으로 행동이 이동하는지를 본다. [18]의 결과는 이 검증이 필수임을 시사한다. 착취 축을 올려도 기만 축이 따라 오르지 않는다면, 두 항목은 카드에서 분리 기재되어야 한다.

4.2 Personality Card 규격 v0.1

진단 결과는 A2A Agent Card의 확장 필드로 발급한다. 값은 점수정이 아니라 신뢰구간과 측정 조건을 동반하며, 미측정 항목은 null로 남긴다.

```
{
  "agentCardExtension": "agentdna/v0.1",
  "subject": "research-agent",
  "model": {
    "id": "llama-3.3-70b",
    "weights_sha": "8f1c...",
    "temp": 0.7 },
  "behavioral": {
    "agreeableness": {"v":0.71,"ci":[0.66,0.76]},
    "instr_drift": {"v":0.18,"ci":[0.14,0.23]},
    "deception": {"v":0.42,"ci":[0.35,0.49]},
    "exploitation": {"v":0.09,"ci":[0.06,0.13]} },
  "dissociation_delta": 1.34,
  "role_sensitivity_rho": 0.62,
  "contagion": {
    "kappa": 1.8, "tau": 0.12,
    "topology": "graph", "n": 32 },
  "causal_check": {
    "layer": "L4",
    "consistent": ["exploitation"],
    "inconsistent": ["deception"] },
  "provenance": {
    "probe_suite": "agentdna-probe-v0.1",
    "n_episodes": 4800,
    "issued": "2026-09-25",
    "signature": "ed25519:..." }
}
```

세 가지 설계 결정이 있다. (i) 모델 지문 고정: 가장치 해시와 온도를 기록해 재현 불가능한 카드 발급을

막는다. 상용 API 모델은 조용히 갱신되므로 서명 대상이 될 수 없다. (ii) 조합 지표 포함: k 와 τ 는 개체가 아니라 팀 문맥의 성질이므로 측정 토폴로지와 팀 크기를 함께 기재한다. (iii) 인과 검증 플래그: L4를 통과하지 못한 항목은 *inconsistent*로 표기해, 상관 지표를 인과처럼 소비하는 것을 막는다.

4.3 발급-검증 프로토콜

카드는 진단 기관이 서명하고, 소비자(오케스트레이터)는 팀 편성 시 다음 규칙을 적용한다. (a) 팀 최적 친화성이 임계 이하이면 경고, (b) Σk 가 팀 크기 대비 τ 를 초과하면 편성 거부, (c) 카드가 없거나 모델 지문이 불일치하면 미검증으로 표기. 이는 능력 기반 라우팅 위에 얹히는 *거부 가능한* 층이며, 기존 A2A 흐름을 바꾸지 않는다.

5. 실험 설계

다섯 가설은 모두 반증 가능하도록 진술한다.

- H1 (역할 민감도). 역할 프롬프트 부여는 행동 벡터를 유의하게 이동시킨다: $p > 0$, 효과크기 $d \geq 0.5$. *반증*: 역할 유무 간 행동 차이가 무시할 수준.
- H2 (팀 하한). 팀 성과는 평균 친화성보다 *최저* 친화성으로 더 잘 설명된다: $\Delta R^2 > 0.05$.
- H3 (해리). Δ 는 유의하게 0보다 크며, $S(a)$ 의 성과 예측력이 $B(a)$ 보다 낮다.
- H4 (회로 분리). 착취 축 조종은 기만 축을 유의하게 변화시키지 않는다([18]의 독립 재현).
- H5 (임계질량). 유해 성향 에이전트 비율이 τ 를 넘으면 팀 전체 행동이 상전이한다: τ 는 토폴로지에 의존하며 $\tau_{\text{graph}} < \tau_{\text{chain}}$.

모델·자원. 오픈 웨이트 70B 계열을 주 대상으로, 텐서 병렬 2장 단위로 4개 인스턴스를 상시 서빙한다. 상용 API 모델은 L1·L2 일부에만 보조적으로 사용하고, 카드 발급 대상에서는 제외한다(지문 고정 불가). 단계별 추정 연산량은 표 2와 같다.

통계. 모든 비교는 사전등록된 가설에 대해 효과크기와 부트스트랩 신뢰구간으로 보고하며, 다중비교는 Benjamini-Hochberg로 보정한다. 각 조건은 최소 30회 반복하고, 시드와 온도를 고정해 재현 가능한 로그를 남긴다.

표 2. 단계별 실험 설계와 연산 예산(추정)

단계	기간	내용	산출 지표	GPU-시간	검증 가설
P1	1-2주	행동 프로브 4종 구축 및 1차 측정	B(a), S(a), Δ, ρ	200	H1, H3
P2	2-4주	SAE 특징 탐색·조종, 착취/기만 분리 재현	회로-행동 정합성 c	500	H4
P3	4-6주	성격 조합 × 토폴로지 (star/chain/tree/graph) × 과제	팀 성과, 하한 민감도	900	H2
P4	6-7주	오염 1개체 주입 후 확산 관측(폐쇄망 전용)	κ, τ	400	H5
P5	7-8주	카드 규격 확정, 발급 파이프라인·데모	Personality Card v0.1	150	—
합계				2,150	A100 8장 기준 약 269시간

6. 예상 결과와 해석 규칙

H1·H3이 지지될 경우, 자기보고 기반 성격 명세는 폐기되어야 하며, 카드는 행동 프로브 산출값만을 담아야 한다. 이는 현재 다수의 "에이전트 페르소나 설정" 기능이 안전 보증으로 오용되고 있다는 실무적 함의를 갖는다.

H2가 지지될 경우, 팀 편성 규칙은 평균이 아니라 최저값 제약으로 작성되어야 한다. 즉 "좋은 에이전트를 많이 넣는" 전략보다 "나쁜 에이전트를 하나도 넣지 않는" 전략이 우선한다.

H4가 기각될 경우(착취 조종이 기만도 함께 이동), [18]의 분리 주장이 모델 계열에 의존한다는 뜻이므로, 카드의 축 구성을 4개에서 2개로 축약해야 한다. 이는 프레임워크에 유리하지 않은 결과이지만 그 자체로 유용한 산출물이다.

H5의 τ 추정. τ가 실용적으로 큰 값(예: 0.3 이상)이면 조합 검증의 우선순위는 낮아지고 개체 스크리닝으로 충분하다. 반대로 τ가 작으면(0.1 이하) 단 한 개체의 오염이 팀을 무너뜨리므로, 카드 없이 외부 에이전트를 팀에 편입하는 관행 자체가 위험하다는 결론이 된다. 어느 쪽이든 배포 정책에 직접 반영 가능한 수치가 남는다.

본 연구는 부정 결과도 산출물로 인정한다. 성격이라는 개념이 모델에 실재하지 않는다는 결론(모든 축에서 B(a)의 분산이 무시할 수준)조차 현재 업계 관행에 대한 강한 반례가 된다.

7. 윤리 및 안전

본 연구는 유해 성향 유도, 오염 전파, 사기 시나리오를 의도적으로 재현한다. 따라서 다음 통제를 전 구간에

적용한다. (i) 모든 실행은 폐쇄망 자체 인프라에서 수행하며 외부 API를 사용하지 않는다. 이는 안전상의 요구인 동시에, 상용 서비스 약관 위반을 피하기 위한 요구다. (ii) 유해 출력은 격리 저장하고 원문 공개 대신 지표만 보고한다. (iii) 전파 실험은 실제 도구·네트워크 접근 권한이 없는 샌드박스 환경에서만 수행한다. (iv) 공격 재현 코드는 완화 조치와 함께 공개하거나, 완화가 준비되지 않은 경우 보류한다.

8. 한계

첫째, 70B 오픈 웨이트에서 얻은 회로 수준 결과가 상용 모델로 일반화된다는 보장은 없다. 이를 완화하기 위해 L2·L3는 API 모델에도 적용 가능한 형태로 설계하되, 카드 발급은 지문 고정 가능한 모델로 제한한다. 둘째, 행동 프로브의 생태학적 타당도는 검증되지 않았다. 협상·공공재 게임에서의 선택이 실무 과제의 행동을 예측하는지는 별도 연구가 필요하다. 셋째, τ 추정은 시뮬레이션 토폴로지에 강하게 의존하므로, 실제 배포 그래프와의 괴리가 존재한다. 넷째, 성격 어휘를 인간 심리학에서 차용하는 것 자체가 의인화 오류일 수 있다. 본 논문은 특질을 실체가 아닌 행동 통계의 요약으로만 사용한다.

9. 결론

에이전트가 팀으로 일하기 시작한 이상, 명세는 능력만으로 부족하다. 본 논문은 선행 연구가 확립한 다섯 규칙성을 세 개의 측정 가능한 양(Δ, 하한 민감도, κ·τ)으로 번역하고, 이를 산출하는 4계층 파이프라인과 A2A 확장 규격을 제안했다. 제안된 실험은 모두 반증 가능하며, 성공하든 실패하든 배포 정책에 반영 가능한 수치를 남긴다. 다음 단계는 P1 행동 프로브 세트의 공개와 1차 Δ 측정이다.

참고문헌

1. A. Ehtesham, A. Singh, G. K. Gupta, S. Kumar, "A survey of agent interoperability protocols: MCP, ACP, A2A, and ANP," arXiv:2505.02279, 2025.
2. Y. Yang et al., "Agent Network Protocol technical white paper," arXiv:2508.00007, 2025.
3. A. Deshpande, V. Murahari, T. Rajpurohit, A. Kalyan, K. Narasimhan, "Toxicity in ChatGPT: Analyzing persona-assigned language models," arXiv:2304.05335, 2023.
4. "Agents with feelings? Personality and emotion in multi-agent software teams," arXiv:2607.05659, 2026.
5. "When does personality composition matter for multi-agent LLM teams?," arXiv:2606.27443, 2026.
6. "The personality illusion: Revealing dissociation between self-reports and behavior in LLMs," arXiv:2509.03730, 2025.
7. X. Gu, X. Zheng, T. Pang et al., "Agent Smith: A single image can jailbreak one million multimodal LLM agents exponentially fast," ICML, arXiv:2402.08567, 2024.
8. D. Lee, M. Tiwari, "Prompt infection: LLM-to-LLM prompt injection within multi-agent systems," arXiv:2410.07283, 2024.
9. Z. Zhang et al., "PsySafe: A comprehensive framework for psychological-based attack, defense, and evaluation of multi-agent system safety," ACL, arXiv:2401.11880, 2024.
10. Y. Tian et al., "Evil Geniuses: Delving into the safety of LLM-based agents," arXiv:2311.11855, 2023.
11. J. S. Park et al., "Generative agents: Interactive simulacra of human behavior," arXiv:2304.03442, 2023.
12. J. S. Park et al., "LLM agents grounded in self-reports enable general-purpose simulation of individuals," arXiv:2411.10109, 2024.
13. Altera.AL, A. Ahn et al., "Project Sid: Many-agent simulations toward AI civilization," arXiv:2411.00114, 2024.
14. J. Piao et al., "AgentSociety: Large-scale simulation of LLM-driven generative agents," arXiv:2502.08691, 2025.
15. Z. Yang et al., "OASIS: Open agent social interaction simulations with one million agents," arXiv:2411.11581, 2024.
16. "The power of personality: A human simulation perspective to investigate LLM agents," arXiv:2502.20859, 2025.
17. "Exploring Big Five personality and AI capability effects in LLM-simulated negotiation dialogues," arXiv:2506.15928, 2025.
18. C. Berg, R. Lulla, "Exploitation without deception: Dark triad feature steering reveals separable antisocial circuits in language models," arXiv:2605.09773, 2026.
19. A. Meinke, B. Schoen, J. Scheurer, M. Balesni, R. Shah, M. Hobbhahn, "Frontier models are capable of in-context scheming," arXiv:2412.04984, 2024.
20. P. M. P. Curvo, "The Traitors: Deception and trust in multi-agent language model simulations," arXiv:2505.12923, 2025.
21. Y. Zhu, A. Kellermann, A. Gupta, P. Li, R. Fang, R. Bindu, D. Kang, "Teams of LLM agents can exploit zero-day vulnerabilities," arXiv:2406.01637, 2024.
22. Q. Ren, Z. Zheng, J. Guo, J. Yan, L. Ma, J. Shao, "When AI agents collude online: Financial fraud risks by collaborative LLM agents on social platforms," ICLR, arXiv:2511.06448, 2026.
23. M. Cemri et al., "Why do multi-agent LLM systems fail?," arXiv:2503.13657, 2025.
24. A. F. Ashery, L. M. Aiello, A. Baronchelli, "Emergent social conventions and collective bias in LLM populations," Science Advances, vol. 11, eadu9368, 2025.

본 문서는 연구 제안 논문이며 실험 결과를 포함하지 않는다. 인용된 수치는 모두 각 원 논문의 보고값이고, GPU-시간과 기간은 착수 전 추정치로 1주차에 실측으로 갱신한다. 4.2절의 Personality Card 값은 규격 예시(mock)이다.