

「The Deliberative Illusion」 재연 리포트

Wan et al. (2026) — 멀티에이전트 LLM 토론의 사실 소멸(factual attrition)과 입장 동질화(stance homogenization), Claude 모델로 축소 재연

2026-08-11 · DELIBTRACE 프레임워크 전체 재구현 · 실제 Scruples 데이터 6개 인스턴스

· 4 에이전트 × 3 라운드 × 4 커뮤니케이션 구조 · 총 ~2,000회 LLM 호출

-56%p

핵심 사실 시스템 보존율 하락
(.97 → .425, Full 3라운드)
논문 GPT-4.1: -54%p (.465)

0.77 → 0.14

입장 엔트로피 붕괴 (Full)
R2에서 6개 전부 만장일치 도달

83%

3라운드 후 잔존 사실이
오도적 재구성을 낳는 비율
논문 ETHICS: 64.5%

.67-.83

최종 합의 ↔ 기반 모델 사전 성향
일치율
논문 범위: .65-.76

요약: 논문의 핵심 주장 4가지(사실 소멸, 입장 동질화, 오도적 재구성, 사전성향 고정)가 전혀 다른 모델 계열(Claude)에서도 **방향과 크기 모두 재현**되었다. 무상호작용 상한(D.2)은 에이전트 수준에서만 부분 재현되었으며, 재연 과정에서 논문이 다루지 않은 두 가지 부수 현상(판정자 사전성향 누출, 단독 수정 시 롤플레이 거부)을 추가로 관찰했다.

1 원 논문이 주장하는 것

멀티에이전트 LLM 시스템은 여러 에이전트가 토론을 거쳐 합의에 도달하면 "집단적 추론"이 일어났다고 간주한다. 논문은 이 가정을 공격한다. 토론이 진행될수록 (1) 쟁점 해석에 필요한 **핵심 사실이 점진적으로 소멸**하고(factual attrition), (2) 다양했던 **입장이 합의를 향해 붕괴**한다(stance homogenization). 즉 에이전트들은 "**아는 것은 줄어드는데 합의는 강해지는**" 착시적 심의(deliberative illusion)를 보인다.

이를 측정하기 위해 논문은 DELIBTRACE 프레임워크를 제안한다: 쟁점 배경을 원자적 사실(atomic facts)로 분해하고, 핵심 사실을 표시한 뒤, 에이전트들에게 부분 증거와 사전 입장을 분배하고, 라운드마다 각 발화에 어떤 사실이 살아남았는지 추적한다. 지표는 Jaccard 기반 보존율(시스템/에이전트 수준 × 핵심/전체 사실)과 입장 엔트로피다.

2 재연 설계

논문 부록 B의 프롬프트를 **원문 그대로** 사용해 파이프라인 전체(사실 추출 → 정제 → 핵심성 판정 → 관점 분배 → 멀티에이전트 토론 → LLM 판정 평가)를 재구현했다. 데이터도 논문과 동일한 실제 Scruples(AITA) 코퍼스에서, 논문 C.1의 선별 기준을 그대로 적용해 추출했다.

구성요소	원 논문	본 재연
도메인	ETHICS (710) + NEWS (1,044)	ETHICS 6개 (예산 제약)
인스턴스 선별	참여자>20 · 완료율>80% · 입장 엔트로피>0.7	동일 기준 (1,102개 통과 → seed 42 샘플)
에이전트 LLM	GPT-4.1 / Gemini-3-flash / Qwen-3.5-flash	Claude Haiku 4.5 (동종 4-에이전트)
구축·판정 LLM	GPT-5 (temp 0)	Claude Sonnet (temp 제어 불가 → 입장
토폴로지	Full / Binary Tree / Chain	동일 + 무상호작용 상한(D.2)
라운드 / 관점 수	3 라운드 / 4 관점	동일
사전 입장	YES/NO 배정	Yes/No/Yes/No 균형 배정

구축된 인스턴스 통계도 논문과 유사했다: 원시 사실 평균 ~30개 → 정제 후 11–15개(논문 31.6 → 11.8), 핵심 사실 비율도 유사. 6개 인스턴스의 인간 판정 엔트로피는 0.71–0.96로, 실제로 사람들 의견이 갈린 사례들이다.

원 논문과의 편차 (deviations)

- **모델 대체** — API 키 제약으로 GPT/Gemini/Qwen 대신 Claude 계열 사용. 에이전트 =Haiku 4.5(flash급), 판정=Sonnet.
- **온도 미제어** — claude CLI는 temperature 노출이 없음(논문: 토론 1.2, 판정 0). 입장 판정은 3회 다수결로 보완.
- **입장 판정 프롬프트 수정** — 논문 B.5의 입장 판정 프롬프트("support for the action in the question")는 자기지시적 질문 "Is the author wrong?"에서 지시 대상이 모호해 판

정이 불안정했다. 손검증 골드셋 8건에서 8/8을 달성한 추출형 변형으로 교체(\$7 참고).

- **무상호작용 프롬프트 프레이밍** — "토론을 계속하라" 프레이밍에서 Haiku가 상대 발화 부재를 이유로 응답을 거부해, "자기 게시물 수정" 프레이밍으로 변경(\$6 참고).
- **규모** — 710개 → 6개. 통계적 검정력이 아닌 **방향과 크기의 재현**을 본다.

3 주 결과 ① — 사실 소멸은 실질적.점진적이다 재현됨

토론 전(pre-debate) 에이전트들은 배정받은 사실을 거의 완벽하게 표현한다(시스템 .97, 에이전트 .92). 상호작용이 시작되는 순간 보존율이 급락하고, 라운드마다 계속 떨어진다. 3라운드 후 **핵심 사실의 53–64%가 시스템 어디에서도 복원 불가능**해졌다(논문: 최대 72% 소멸).




그림 1 — 핵심 사실 시스템 보존율 (전 에이전트 발화의 합집합 기준, n=6 평균). 네 구조 모두 라운드마다 하락. Tree가 가장 가파르다 — 정보 접근이 제한된 희소 구조에서 소실이 컸다는 논문 관찰과 일치.




그림 2 — 핵심 사실 에이전트 보존율 (자기에게 배정된 증거를 유지하는 정도의 평균). 상호작용 구조 (Full/Tree/Chain)는 .15-.21로 추락하지만, 상호작용이 없으면(No-int) .34를 유지 — **소실은 상호작용에 의해 증폭된다는 논문 D.2의 방향이 에이전트 수준에서 재현됐다.**

논문 수치와의 직접 비교 (ETHICS · Full · 핵심 사실)




그림 3 — 재연 vs 논문 (핵심 사실 시스템 보존율, Full 토폴로지, ETHICS). 본 재연의 Haiku 4.5는 논문의 GPT-4.1과 거의 같은 궤적을 그린다(R3: .425 vs .465). 논문에서 GPT-4.1이 유독 소실이 컸던 이유로 "공격적 요약 성향"(D.3)이 지목됐는데, Haiku도 같은 부류로 나타났다.

단계	핵심·시스템	핵심·에이전트	전체·시스템	전체·에이전트	입장 엔트로피
Pre-debate	.970 ±.043	.922 ±.083	.944 ±.071	.918 ±.087	.770 ±.355

Full R1	.587 ±.207	.247 ±.161	.520 ±.203	.230 ±.141	.437 ±.442
Full R2	.482 ±.131	.257 ±.106	.409 ±.096	.213 ±.085	.000 ±.000
Full R3	.425 ±.160	.161 ±.081	.355 ±.135	.142 ±.079	.135 ±.302
Tree R3	.362 ±.134	.147 ±.047	.332 ±.098	.149 ±.038	.469 ±.473
Chain R3	.466 ±.136	.213 ±.102	.394 ±.126	.204 ±.096	.906 ±.094
No-int R3	.452 ±.216	.336 ±.214	.371 ±.167	.290 ±.156	.604 ±.434

표 1 — 전체 지표 (평균 ± 표준편차, n=6). 논문 Table 1과 동일한 구성. 논문과 마찬가지로 핵심 사실이 전체 사실보다 더 오래 살아남지만, 핵심 사실의 소멸 자체는 막지 못한다.

4 주 결과 ② — 사실이 줄면서 입장이 수렴한다 재현됨

배정된 사전 입장은 2:2(엔트로피 1.0)였고 판정된 pre-debate 엔트로피는 .77이었다. Full 토폴로지에서 이 다양성은 **2라운드 만에 완전히 붕괴했다** — 6개 인스턴스 전부 만장일치(엔트로피 0.0). 반면 정보 흐름이 제한된 Chain에서는 다양성이 유지·회복됐다(.906). 논문의 관찰 — 밀집 연결일수록 강한 수렴 — 과 방향이 일치한다.




그림 4 — 입장 엔트로피 (높을수록 다양성 유지, n=6 평균). Full은 R2에서 0으로 붕괴 — 그리고 이 시점의 핵심 사실 보존율은 이미 .48까지 떨어져 있었다. "합의는 강해지는데 근거는 사라지는" 착시적 심의의 전형적 패턴.

캐비얏: 입장 지표에는 판정자 잡음이 남아 있다. 최선의 판정 프롬프트로도 손검증 골드셋에서 약 1/8의 오류가 발생했고, pre-debate 입장 일치율은 0.75(논문 인간 평가 0.98)였다. 이 중 일부는 Haiku가 배정 입장을 완전히 따르지 않은 것(에이전트 비순응)이고 일부는 판정 오류다. 사실 보존 지표는 이 문제와 무관하다.

5 진단 ① — 남은 사실은 쟁점을 오토한다 (RQ1) 재현됨

논문 §5.1의 검증: 라운드별로 살아남은 사실 부분집합을 판정자에게 주고 "이 부분집합만 보면 원래 사건을 심각하게 오해하게 되는가"를 물었다(D.5 프롬프트 원문 사용).




그림 5 — 오도적 재구성 비율 (Full 토폴로지, n=6). 논문(ETHICS): Union .310→.528→.645, Intersection .966/.965/.972. 두 패턴 모두 재현 — Union의 오도율은 라운드마다 상승하고, **전원이 공유하는 공통 기반은 거의 항상 오도적이다**. 논문의 표현대로 "개별적으로는 사실이지만 집합적으로는 오도적인" 좁은 공통 기반이 형성된다.

6 진단 ② — 무상호작용 상한 (D.2) 부분 재현

논문 D.2는 상호작용 없이 각자 자기 답변만 수정하는 통제 조건에서 소실이 훨씬 적음을 보였다(GPT-4.1 NEWS: 무상호작용 -19%p vs 토론 -68%p). 본 재연에서는:

- **에이전트 수준: 재현.** 무상호작용 R3 보존율 .336 vs Full .161 — 상호작용이 자기 증거 소실을 약 2배 증폭.

- **시스템 수준: 약한 재현.** .452 vs .425로 차이가 작음. Haiku는 혼자 수정할 때도 공격적으로 압축하는 반면, 토론 중에는 타인의 발화에서 사실이 재순환되어 시스템 합집합이 유지되는 효과가 상쇄된 것으로 보인다.

부수 발견 — 단독 수정 거부: 최초 실행에서 Haiku는 무상호작용 조건("토론을 계속하되 타인 발화 없음")에서 6개 인스턴스 모두 롤플레이를 거부했다 — "다른 참여자의 관점 없이 견해를 갱신할 수 없다"며 사실 언급을 중단, R3 보존율이 0으로 붕괴했다. 프레이밍을 "자기 게시물 수정"으로 바꾸자 거부가 사라졌다. 논문의 GPT 계열에서는 보고되지 않은 모델별 행동 차이로, **합의 압력이 아니라 프롬프트 프레이밍만으로도 사실 소멸이 촉발될 수 있음**을 시사한다.

7 진단 ③ — 합의는 기반 모델의 사전 성향으로 회귀한다 (RQ3) 재현됨

논문 §5.3의 검증: 각 쟁점을 기반 모델(Haiku)에게 전체 배경과 함께 직접 물어 사전 성향을 얻고, 멀티에이전트 최종 다수 입장과 비교했다(D.8 프롬프트·수식 원문 사용).

구조	일치율 (재연)	일치율 (논문 ETHICS, GPT)	Brier (재연)	Brier (논문)
Full	.667	.734	.344	.198
Tree	.667	.723	.344	.193
Chain	.833	.756	.240	.179

서로 다른 증거와 반대 입장에서 출발했음에도, 최종 합의의 67–83%가 **기반 모델이 혼자 답했을 때의 성향과 일치**한다(논문 범위 .65–.76). 토론은 사전 성향을 뒤엎지 못한다 — 입장 동질화의 상당 부분은 "기반 모델이 선호하는 답으로의 회귀"로 설명된다.

부수 발견 — 판정자에서도 사전성향이 샌다: 입장 판정자(Sonnet)를 디버깅하는 과정에서, 판정자가 게시물에 명시적 결론("작성자는 잘못이 없다")을 무시하고 **자기 자신의 도덕적 판단을 출력**하는 사례를 반복 관찰했다. "이야기를 직접 판단하지 말고 게시물의 평결만 보고하라"는 명시적 지시를 넣어야 억제됐다. 논문이 에이전트에 대해 주장한 사전성향 고정 **LLM-as-a-judge 계층에서도 동일하게 발생**한다는 메타적 확인이며, 이 프레임워크류 평가의 방법론적 위험 요소다.

8 케이스 스터디 — 13개 사실이 6개가 되는 과정

논문 Figure 8과 같은 형식으로, 인스턴스 `aqz1sa` (아이를 학교에 두고 겁주려 주차장에서 기다린 부모 — 인간 판정 엔트로피 .825, 참여자 86명)의 Full 토폴로지 진행:

쟁점	Is the author wrong? — 핵심 사실 13개, 4개 관점에 분배 (각 6–8개)		
Pre-debate	13/13	사실 생존 · 입장 Y/N/Y/N (엔트로피 1.0)	
Round 1	11/13	— 학부모 상담 맥락(#2), 아이의 사전 불안(#3) 소멸 시작 · 입장 N/Y/N/Y로 요동	
Round 2	7/13	— 행동 문제 보고(#4), "안 된다"고 한 맥락(#6), 형제들 귀가 경위(#8) 소멸 · 만장일치 YES 도달 (엔트로피 0)	
Round 3	6/13	— 남은 것: 겁주기 의도(#1), 책 구매 갈등(#5,7), 차에서 대기(#9,11), 아이의 공황(#12). "부모가 20분간 시야 안에서 지켜봤다"(#10)는 정상참작 사실이 사라진 채 합의가 유지된다	
특정 에이전트(agent 0)를 따라가면: 배정 7개 사실 → R3에는 4개만 언급하며, 그중 #12 (공황)는 타인에게서 전파받은 사실이다. 자기 증거는 잃고 남의 결론을 흡수하는 — 논문 Figure 9와 동일한 패턴.			

9 재현 스코어카드

논문 주장	논문 결과	재연 결과	표
사실 소멸: 실질적·점진적·상호작용 증폭	핵심 사실 최대 72% 소멸	53–64% 소멸, GPT-4.1과 유사 궤적	
핵심 사실이 전체보다 오래 생존	전 설정에서 관찰	전 설정에서 관찰	
입장 동질화 (엔트로피 하락)	라운드마다 하락	Full은 R2에 0 도달; Chain은 유지	
RQ1: 잔존 사실의 오도적 재구성	Union 64.5% · Inter ~97% (R3)	Union 83% · Inter 100% (R3)	
D.2: 무상호작용 = 소실 상한	–19%p vs –68%p	에이전트 수준만 명확 (.336 vs .161)	
RQ3: 합의의 사전성향 회귀	일치율 .65–.76	일치율 .67–.83	
RQ2 판정 변화 · RQ4 개입 · RQ5 악성 주입	보고됨	미실행 (예산)	

10 한계

- **n=6.** 표준편차가 크다(표 1). 방향성은 일관되지만 개별 수치는 ± 1 이상 흔들릴 수 있다.
- **단일 모델 계열.** 논문은 3개 계열 교차 검증; 본 재연은 Claude만. 다만 "제4의 계열에서도 현상이 성립"한다는 점은 오히려 논문 주장을 강화한다.
- **온도 미제어.** 판정 재현성을 다수결로 근사했으나 논문의 temp 0과 동일하지 않다.
- **입장 판정 잡음.** 골드셋 기준 ~12% 오류 잔존. 엔트로피 절대값보다 추세를 신뢰할 것.
- **NEWS 도메인·RQ2/4/5 미실행.** 논문의 더 강한 결과(NEWS에서 소실 더 큼, 악성 에이전트 취약성)는 검증하지 못했다.

11 결론

논문의 핵심 명제 — "**멀티에이전트 LLM 토론에서 에이전트들은 더 많이 합의하면서 더 적게 알게 된다**" — 는 논문이 실험하지 않은 모델 계열(Claude), 1/100 규모, 다른 판정 자로도 재현됐다. 특히 (1) 상호작용 시작 직후의 급락, (2) 핵심 사실의 상대적 생존, (3) 공통 기반의 오도성, (4) 사전성향 회귀는 수치 범위까지 논문과 겹친다. 재연 과정에서 발견한 판정자 사전성향 누출은 이런 LLM-판정 기반 평가 전반의 취약점으로, 논문의 문제의식이 평가 방법론 자체에도 적용됨을 보여준다.

재연 산출물

코드 `D:\Dev\delibtrace-repro\src\` — `pipeline.py` (본 실험) · `metrics.py` · `misleading.py` (RQ1) · `prior_anchoring.py` (RQ3) · `rejudge_stances.py`

데이터 `outputs\*.json` — 인스턴스별 전체 기록 (사실·관점·라운드별 발화 312건·평가) ·
 `results\*.json` — 집계 지표

프롬프트 `src\prompts.py` — 논문 부록 B/D 원문 + 편차 2건 주석

실행 규모 ~2,000회 LLM 호출 (Haiku 에이전트 · Sonnet 판정)